```
GetCandidateReplica
// RegroupReplicasGTID will choose a candidate replica of a given
instance, and take its siblings using GTID
func RegroupReplicasGTID(
   masterKey *InstanceKey, // 实参传进来的是 挂掉的旧主库
   returnReplicaEvenOnFailureToRegroup bool, // 实参传进来的是 true
   startReplicationOnCandidate bool, // 实参传进来的是 false
   onCandidateReplicaChosen func(*Instance), // 实参传进来的是 nil
   postponedFunctionsContainer *PostponedFunctionsContainer,
   postponeAllMatchOperations func(*Instance, bool) bool, // 实参传进
来的是 promotedReplicaIsIdeal 函数
)
RegroupReplicasGTID will choose a candidate replica of a given instance,
and take its siblings using GTID
英文简简单单一句话, 中文不知道咋翻译.. 我理解就是 RegroupReplicasGTID
会从目标实例(即 DeadMaster)的从库中选出一个 candidate 出来,然后提升他
为新主库,并接管所有的从库
要理解 RegroupReplicasGTID , 还是要先看它调用的 GetCandidateReplica
// GetCandidateReplica chooses the best replica to promote given a
(possibly dead) master
func GetCandidateReplica(masterKey *InstanceKey, forRematchPurposes
                  [](*Instance), [](*Instance),
bool)
       (*Instance,
                                                  [] (*Instance),
[](*Instance), error) {
   // masterKey 实参传进来的是 挂掉的旧主库. InstanceKey 结构体里只有
Hostname 和 Port
   // forRematchPurposes 实参传进来是 true
   // 声明变量, 这是一个指针
   var candidateReplica *Instance
   aheadReplicas := [](*Instance){} // 字面量声明, 所以
aheadReplicas != nil
   equalReplicas := [](*Instance){}
   laterReplicas := [](*Instance) {}
   cannotReplicateReplicas := [](*Instance) {}
   dataCenterHint := ""
   // 这里实际是根据 Hostname 和 Port 读取 backend db database instance
     实例化了一个 instance, 使用 readInstanceRow 填充了各种属性,
is candidate, promotion rule 等等
   if master, _, _ := ReadInstance(masterKey); master != nil {
```

dataCenterHint = master.DataCenter

```
// 返回给定主站的副本列表,用于候选选择。
   // 就是把 masterKey 的所有从库读出来了,返回一个[](*Instance)
   replicas, err := getReplicasForSorting(masterKey, false)
   if err != nil {
       // 如果有 err, 这里直接 return. 注意此时 candidateReplica 是等于
nil 的
                 candidateReplica,
       return
                                    aheadReplicas,
                                                      equalReplicas,
laterReplicas, cannotReplicateReplicas, err
   // type StopReplicationMethod string
   // const (
   //
           NoStopReplication
                                           StopReplicationMethod
"NoStopReplication"
        StopReplicationNormal
"StopReplicationNormal"
        StopReplicationNice
"StopReplicationNice"
   // )
   stopReplicationMethod := NoStopReplication
   // forRematchPurposes 实参传进来是 true
   if forRematchPurposes {
                                                             所 以
       stopReplicationMethod
                                   StopReplicationNice
                                                        //
                              =
stopReplicationMethod 是 StopReplicationNice
   // 传入了所有的从库, StopReplicationNice, 和 主库的数据中心
   // 返回根据 exec coordinates 排序的从库列表
   replicas
                               sortedReplicasDataCenterHint(replicas,
stopReplicationMethod, dataCenterHint)
   if len(replicas) == 0 {
       return candidateReplica,
                                    aheadReplicas,
                                                      equalReplicas,
laterReplicas, cannotReplicateReplicas, fmt.Errorf("No replicas found
for %+v", *masterKey)
   candidateReplica,
                      aheadReplicas,
                                      equalReplicas,
                                                      laterReplicas,
cannotReplicateReplicas, err = chooseCandidateReplica(replicas)
   if err != nil {
       return
                candidateReplica,
                                    aheadReplicas,
                                                      equalReplicas,
laterReplicas, cannotReplicateReplicas, err
   if candidateReplica != nil {
       mostUpToDateReplica := replicas[0]
```

candidateReplica. ExecBinlogCoordinates. SmallerThan(&mostUpToDateReplic a. ExecBinlogCoordinates) {

log. Warningf ("GetCandidateReplica: chosen replica: %+v is %+v", behind most-up-to-date replica: candidateReplica. Key, mostUpToDateReplica.Key)

log. Debugf ("GetCandidateReplica: candidate: %+v. ahead: equal: %d, late: %d, break: %d", candidateReplica.Key, len (aheadReplicas), len (equalReplicas), len(laterReplicas), len(cannotReplicateReplicas))

candidateReplica, return aheadReplicas, equalReplicas, laterReplicas, cannotReplicateReplicas, nil

GetCandidateReplica 首先根据 masterKey (只包含 Hostname 和 Port )查询 Backend DB的 database instance 表生成了一个 master"对象" 然后从 Backend DB 中查询出 master 的所有的从库,返回一个包含所有从库\*Instance 的切片 replicas

## 注意

如果在"获取"从库的过程中出现 error ,则 GetCandidateReplica 会终止直接 return. 而此时 candidateReplica 是等于 nil 的

接着调用 sortedReplicasDataCenterHint 对 replicas 进行排序. 接下来先展 开说一下这个函数

```
sortedReplicasDataCenterHint
```

```
// sortedReplicas returns the list of replicas of some master, sorted
by exec coordinates
// (most up-to-date replica first).
// This function assumes given `replicas` argument is indeed a list of
instances all replicating
// from the same master (the result of `getReplicasForSorting()` is
appropriate)
func
           sortedReplicasDataCenterHint(replicas
                                                       [](*Instance),
stopReplicationMethod StopReplicationMethod, dataCenterHint string)
[](*Instance) {
   if len(replicas) <= 1 { // 如果只有一个从库,直接返回
       return replicas
```

// InstanceBulkOperationsWaitTimeoutSeconds 默认 10s

// 先 StopReplicationNicely 超时 10s, 如果超时了也只是记了日志. 然

后 StopReplication

// 然后 sortInstancesDataCenterHint. 这 要 看 NewInstancesSorterByExec 的 Less 方法如何实现. 简单说就是 ExecBinlogCoordinates 大的放前面,如果 ExecBinlogCoordinates 一样, Datacenter和 DeadMaster一样的放前面

replicas = StopReplicas(replicas, stopReplicationMethod,
time.Duration(config.Config.InstanceBulkOperationsWaitTimeoutSeconds)\*
time.Second)

replicas = RemoveNilInstances(replicas)

```
sortInstancesDataCenterHint(replicas, dataCenterHint)
for _, replica := range replicas {
    log.Debugf("- sorted replica: %+v %+v", replica.Key,
replica.ExecBinlogCoordinates)
}
return replicas
```

从注释可以看出 sortedReplicas 会返回一个按 exec coordinates 排序的从库列 表 (most up-to-date first) sortedReplicasDataCenterHint 先调用StopReplicas,StopReplicas做了几件事:

对于本例,stopReplicationMethod 是 StopReplicationNice

并行的在所有从库执行 StopReplicationNicely. StopReplicationNicely 会先 stop slave io\_thread, start slave sql\_thread, 然后对所有非延迟从库 WaitForSQLThreadUpToDate, 最多等待 InstanceBulkOperationsWaitTimeoutSeconds 秒(也就是默认 10s)

如果超过 InstanceBulkOperationsWaitTimeoutSeconds 秒, SQL\_THREAD 还是没有应用完所有日志,也不等了.

等待超时不会引发异常

StopReplicationNicely 执行完成后, 执行 StopReplication. 实际就是执行 stop slave

```
对比 MHA
```

}

```
MHA 其实会在 Dead Master Shutdown Phase 停所有从库 io_thread
MasterFailover.pm
sub do_master_failover {
    ...
    $log->info("* Phase 2: Dead Master Shutdown Phase..\n");
    $log->info();
```

```
force_shutdown($dead_master);
    $log->info("* Phase 2: Dead Master Shutdown Phase completed.\n");
}
sub force shutdown($) {
  my $slave_io_stopper = new Parallel::ForkManager( $#alive_slaves +
1);
  my \$stop io failed = 0;
  $slave_io_stopper->run_on_start(
    sub {
     my ( $pid, $target ) = @_;
    }
 );
  $slave io stopper->run on finish(
    sub {
     my ( $pid, $exit_code, $target ) = @_;
     return if ( $target->{ignore fail} );
     $stop_io_failed = 1 if ($exit_code);
  );
  foreach my $target (@alive_slaves) {
    $slave_io_stopper->start($target) and next;
    eval {
     $SIG{INT} = $SIG{HUP} = $SIG{QUIT} = $SIG{TERM} = "DEFAULT";
     my $rc = $target->stop io thread();
     $slave_io_stopper->finish($rc);
    };
    if ($@) {
     $log->error($@);
     undef $@;
     $slave_io_stopper->finish(1);
    $slave_io_stopper->finish(0);
这是很合理的, 只要开始 Failover 了, 就说明 MHA 认为主库已经挂了, 那么
停 io_thread 再根据 Master_Log_File 和 Read_Master_Log_Pos 选 latest
slave 是 没问题的
```

ServerManager.pm

```
sub identify_latest_slaves($$) {
  my $self
                  = shift;
  my $find_oldest = shift;
  $find oldest = 0 unless ($find oldest);
           = $self\rightarrow{logger};
  my @slaves = $self->get_alive_slaves();
  my @latest = ();
  foreach (@slaves) {
    my $a = $latest[0] {Master Log File};
    my $b = $latest[0] {Read_Master_Log_Pos};
      !$find oldest
      && (
           (!$a && !defined($b))
        | ( $_->{Master_Log_File} gt $latest[0] {Master_Log_File} )
        || ( ( $_->{Master_Log_File} ge $latest[0]{Master_Log_File} )
                             _->\{Read\_Master\_Log\_Pos\}
$latest[0] {Read Master Log Pos} )
      )
      )
    {
      @latest = ();
      push(@latest, $ );
    elsif (
      $find_oldest
      && (
           (!$a && !defined($b))
        || ( \$_->{Master_Log_File} lt \$latest[0] {Master_Log_File} )
        | ( ( $ ->{Master Log File} le $latest[0]{Master Log File} )
                             $_->{Read_Master_Log_Pos}
          &&
$latest[0]{Read_Master_Log_Pos} )
      )
      )
      @latest = ();
      push(@latest, $ );
    elsif ( ( $ ->{Master Log File} eq $latest[0]{Master Log File} )
                                $_->{Read_Master_Log_Pos}
$latest[0] {Read_Master_Log_Pos} ) )
      push(@latest, $ );
```

```
}
  foreach (@latest) {
    _{-}{latest} = 1 if ( !\find_oldest );
    $ \rightarrow {oldest} = 1 \text{ if ($find oldest)};
  $log->info(
    sprintf(
      "The %s binary log file/position on all slaves is". " %s:%d\n",
      $find oldest ? "oldest" : "latest", $latest[0] {Master Log File},
      $latest[0] {Read_Master_Log_Pos}
    )
  );
  if ( $latest[0] {Retrieved_Gtid_Set} ) {
    $log->info(
      sprintf(
                        "Retrieved
                                            Gtid
                                                         Set:
                                                                       %s",
$latest[0] {Retrieved Gtid Set} ) );
  if ($find oldest) {
    $self->set_oldest_slaves( \@latest );
  else {
    $self->set_latest_slaves( \@latest );
  }
```

orchestrator 是根据 ExecBinlogCoordinates 比较出 latest slave

ExecBinlogCoordinates 是应用 binlog 坐标的意思 对应 show slave status 中的

Relay\_Master\_Log\_File

Exec\_Master\_Log\_Pos 表示 sql\_thread 已经应用了主库哪个 binlog 哪个位置的日志.

然而若想不丢数据,则应该根据 ReadBinlogCoordinates 比较出 latest slave, 也就是 MHA 的实现方式,即

Master Log File

Read\_Master\_Log\_Pos 使用 ExecBinlogCoordinates 选 Latest Slave 是可能丢数据的(即使开了半同步),可以通过 tc 命令轻松复现 orc 这种选 latest slave 导致的丢数据问题.

具体模拟方法见 issue: https://github.com/openark/orchestrator/issues/1312 我修改了NewInstancesSorterByExec的Less的方法,改为使用ReadBinlogCoordinates选择latest slave,在公司的分支解决了上述问题.

以我对 Orchestrator 的了解, Orchestrator 目标是追求可用性优先, 而非数据 完整性. 很多公司也使用了 Orchestrator, 我感觉未必知道有这个问题, 或者说,别问,问就是"我们追求可用性".

现在的问题是,即便开了半同步,也可能丢数据.

然而矛盾的点是,线上主从的复制延迟是大家都要监控和管理的,不会长期处于高延迟状态,起码我经历的公司都是这样,99.9%的集群主从延迟在1s内.个别集群在高峰期会升高一点,但很快又会下降;又或者这些集群本身就是AP型业务.

那么既然我们可以保证复制延迟小于 1s, 根据 ReadBinlogCoordinates 选择 Latest slave 又能导致"恢复时间"增大多少呢?而为了这几秒的快速恢复,你又要花多少时间修复数据呢?

那么最准确的方式是要等所有 slave sql\_thread 跑完. orchestrator 虽然调用了 WaitForSQLThreadUpToDate ,但只等待了 10s(超时). 随后运行 sortInstancesDataCenterHint 函数

```
// sortInstances shuffles given list of instances according to some
logic
                                                        [](*Instance),
func
           sortInstancesDataCenterHint(instances
dataCenterHint string) {
   sort. Sort (sort. Reverse (NewInstancesSorterByExec (instances,
dataCenterHint)))
这里做了个 Reverse 排序,具体如何排序的,要看 NewInstancesSorterByExec
的 Less 方法
关于 sort. Reverse
type reverse struct {
// This embedded Interface permits Reverse to use the methods of
// another Interface implementation.
Interface
// Less returns the opposite of the embedded implementation's Less
method.
func (r reverse) Less(i, j int) bool {
return r. Interface. Less (j, i)
}>
// Reverse returns the reverse order for data.
func Reverse(data Interface) Interface {
 return &reverse {data}
```

}

sort. Reverse 返回的是一个 \*reverse. reverse 结构体就一个匿名字段 Interface reverse 上线了 Less 方法, 他本质就是使用 Interface. Less ,只不过调换了参数顺序 所以 Reverse() 虽然返回的是初始数据,但是改变了数据的 Less() 方法, 在排序时调用这个就会产生逆排序的效果.

NewInstancesSorterByExec 的 Less 方法

```
func (this *InstancesSorterByExec) Less(i, j int) bool {
  // Returning "true" in this function means [i] is "smaller" than [j],
  // which will lead to [j] be a better candidate for promotion
  // Sh*t happens. We just might get nil while attempting to
discover/recover
                  if this.instances[i] == nil {
     return false
  if this.instances[j] == nil {
     return true
  if
this.instances[i].ExecBinlogCoordinates.Equals(&this.instances[j].Exec
BinlogCoordinates) {
     // Secondary sorting: "smaller" if not logging replica updates
                        this.instances[j].LogReplicationUpdatesEnabled
&& !this.instances[i].LogReplicationUpdatesEnabled {
        return true
     // Next sorting: "smaller" if of higher version (this will be
reversed eventually)
     // Idea is that given 5.6 a& 5.7 both of the exact position, we
will want to promote
     // the 5.6 on top of 5.7, as the other way around is invalid
     if this.instances[j].IsSmallerMajorVersion(this.instances[i]) {
         return true
     // Next sorting: "smaller" if of larger binlog-format (this will
be reversed eventually)
     // Idea is that given ROW & STATEMENT both of the exact position,
we will want to promote
     // the STATEMENT on top of ROW, as the other way around is invalid
     if this.instances[j].IsSmallerBinlogFormat(this.instances[i]) {
        return true
     // Prefer local datacenter:
           this.instances[j].DataCenter
                                         == this.dataCenter
                                                                    &&
```

```
this.instances[i].DataCenter != this.dataCenter {
        return true
     }
     // Prefer if not having errant GTID
              this.instances[j].GtidErrant
                                                                  &&
                                                ==
this.instances[i].GtidErrant != "" {
        return true
     }
     // Prefer candidates:
this. instances[j]. PromotionRule. BetterThan (this. instances[i]. Promotion
Rule) {
        return true
     }
                                                              return
this.instances[i].ExecBinlogCoordinates.SmallerThan(&this.instances[j]
.ExecBinlogCoordinates)
}
简 单 来 说 , 就 是 根 据  ExecBinlogCoordinates 比 较 , 如 果
ExecBinlogCoordinates 相同在比 DataCenter , DataCenter 与 DeadMaster 一
样的为"大"
instance. ExecBinlogCoordinates. LogFile
                                                                   =
m. GetString("Relay_Master_Log_File")
instance. ExecBinlogCoordinates. LogPos
m. GetInt64("Exec_Master_Log_Pos")
那么至此 sortInstancesDataCenterHint 干了啥也就清楚了,就是排了个序,把
```

那么至此 sortInstancesDataCenterHint 干了啥也就清楚了,就是排了个序,把 most up-to-date 从库放在最前面,如果两个从库 ExecBinlogCoordinates 一样,则从库所在数据中心和主库一样的放前面

首要条件是 ExecBinlogCoordinates. PromotionRule 的"好坏"只是最次要的排序条件(因为他在最后一个 if 里). ExecBinlogCoordinates 相同时, 排序优先级是:

```
LogReplicationUpdatesEnabled
SmallerMajorVersion
SmallerBinlogFormat
same DataCenter with dead master
GtidErrant == ""
PromotionRule
```

接下来 GetCandidateReplica 会调用 chooseCandidateReplica ,初步选一个candidate , chooseCandidateReplica 接收的参数就是刚刚sortedReplicasDataCenterHint返回的排序后的 replicas 切片

```
chooseCandidateReplica
// chooseCandidateReplica
func chooseCandidateReplica(replicas [](*Instance)) (candidateReplica
*Instance,
              aheadReplicas,
                                equalReplicas,
                                                   laterReplicas,
cannotReplicateReplicas [](*Instance), err error) {
   if len(replicas) == 0 {
               candidateReplica,
       return
                                  aheadReplicas,
                                                  equalReplicas,
laterReplicas, cannotReplicateReplicas, fmt.Errorf("No replicas found
given in chooseCandidateReplica")
   // 返回在给定实例中发现的主要(最常见)的 Major 版本
   // 比如 replicas 里有三个实例, 5.6.30, 5.7.32,
                                                             那
                                                     5. 7. 26.
priorityMajorVersion 就是 5.7
   priorityMajorVersion,
                                                              :=
getPriorityMajorVersionForCandidate(replicas)
   // 返回在给定实例中发现的主要(最常见) binlog 格式
   // 比如 replicas 里有三个实例, mixed, row,
                                                           那么
                                                     row.
priorityBinlogFormat 是 row
   priorityBinlogFormat,
                                                              :=
getPriorityBinlogFormatForCandidate(replicas)
   for , replica := range replicas {
       replica := replica
       if isGenerallyValidAsCandidateReplica(replica) && // 做一些简单
的
                               IsLastCheckValid,
                    比
                         如
                                                  LogBinEnabled,
LogReplicationUpdatesEnabled(前三个都应该为 true), IsBinlogServer(应为
false)
           !IsBannedFromBeingCandidateReplica(replica) && // 是否被参
数 PromotionIgnoreHostnameFilters 匹配,希望不匹配
           !IsSmallerMajorVersion(priorityMajorVersion,
replica. MajorVersionString()) &  // 希望
                                             replica
priorityMajorVersion. 更希望高版本做低版本从库. 那比如最常见版本是 5.6,
然后有一个 replica 是 5.7,他是那个 most up-to-date 的从库,到这里一比较,
他就不符合条件,就被 pass 了
          !IsSmallerBinlogFormat (priorityBinlogFormat,
replica. Binlog format) { // 希望比如 priorityBinlogFormat row,
replica 是 mixed 或 statement
          // this is the one
          candidateReplica = replica
          break
   // 不用想那么多, 以我们的场景, 不存在 Major 版本不同的,
```

```
Binlog_format 也都是 row

// 那 只 要 这 个 从 库 没 什 么 ″ 毛 病 ″, 也 没 在
PromotionIgnoreHostnameFilters 中 , 那 基 本 上 replicas[0] 就 是
candidateReplica

// 如果上面的所有 replica 都不符合条件, candidateReplica 就=nil, 就
会进入这个 if
  if candidateReplica == nil {
    // Unable to find a candidate that will master others.
    // Instead, pick a (single) replica which is not banned.
```

// 能走到这里,说明第一次循环就找到 candidateReplica 了
// 把 candidateReplica 从 replicas 里移除
replicas = RemoveInstance(replicas, &candidateReplica.Key)

// 迭代 replicas
for \_, replica := range replicas {
 replica := replica

// 如果这个实例不能做 candidateReplica 的从库, 就把它放到 cannotReplicateReplicas 切片里

```
if err != nil {
              log. Errorf ("chooseCandidateReplica(): error checking
CanReplicateFrom(). replica: %v; error: %v", replica.Key, err)
           如果这个实例
                               ExecBinlogCoordinates
                                                     SmallerThan
candidateReplica. ExecBinlogCoordinates, 放到 laterReplicas
                                 else
replica. ExecBinlogCoordinates. SmallerThan(&candidateReplica. ExecBinlog
Coordinates) {
           laterReplicas = append(laterReplicas, replica)
                   这个
                           实 例
                果
                                       ExecBinlogCoordinates
candidateReplica.ExecBinlogCoordinates, 放到 equalReplicas
                                                             if
                                 else
replica. ExecBinlogCoordinates. Equals (&candidateReplica. ExecBinlogCoord
inates) {
          equalReplicas = append(equalReplicas, replica)
                      说明这个实例
       // 佛足额,
                                         ExecBinlogCoordinates
candidateReplica.ExecBinlogCoordinates, 放到 aheadReplicas
       } else {
          // lost due to being more advanced/ahead of chosen replica.
          aheadReplicas = append (aheadReplicas, replica)
   return
             candidateReplica,
                                 aheadReplicas,
                                                  equalReplicas,
laterReplicas, cannotReplicateReplicas, err
chooseCandidateReplica 选了一个 candidateReplica 出来 并且对其他
replica 做了归类(laterReplicas, equalReplicas, aheadReplicas)
CanReplicateFrom
                    的
                                  体
                                         逻
                                                辑
                           具
                                                             看
https://github.com/Fanduzi/orchestrator-zh-doc 配置参数详解-Ⅱ 中对该
参数的详细解释
从代码可以看出 orchestrator 并不会以 0 数据丢失为最优先级选择 candidate
   // 返回在给定实例中发现的主要(最常见)的 Major 版本
   // 比如 replicas 里有三个实例, 5.6.30, 5.7.32,
                                                             那
priorityMajorVersion 就是 5.7
   priorityMajorVersion,
                                                             :=
getPriorityMajorVersionForCandidate(replicas)
   // 返回在给定实例中发现的主要(最常见) binlog 格式
   // 比如 replicas 里有三个实例, mixed, row,
                                                           那么
                                                     row.
```

```
priorityBinlogFormat 是 row
priorityBinlogFormat,
getPriorityBinlogFormatForCandidate(replicas)
```

```
for _, replica := range replicas {
    replica := replica
```

if isGenerallyValidAsCandidateReplica(replica) && // 做一些简单的 检测 , 比如 IsLastCheckValid, LogBinEnabled, LogReplicationUpdatesEnabled(前三个都应该为 true), IsBinlogServer(应为false)

:=

!IsBannedFromBeingCandidateReplica(replica) && // 是否被参数 PromotionIgnoreHostnameFilters 匹配,希望不匹配

!IsSmallerMajorVersion(priorityMajorVersion, replica. MajorVersionString()) & // 希望 replica 版本 <= priorityMajorVersion. 更希望高版本做低版本从库. 那比如最常见版本是 5.6, 然后有一个 replica 是 5.7. 他是那个 most\_up-to-date 的从库. 到这里一比较.

然后有一个 replica 是 5.7, 他是那个 most up-to-date 的从库, 到这里一比较, 他就不符合条件, 就被 pass 了

!IsSmallerBinlogFormat(priorityBinlogFormat,

replica. Binlog\_format) { // 希望比如 priorityBinlogFormat row, 那 replica是 mixed 或 statement

```
// this is the one
  candidateReplica = replica
  break
}
```

上述代码中的 replicas 是 sortInstancesDataCenterHint 返回的,按ExecBinlogCoordinates 从大到小排序的切片(即 ExecBinlogCoordinates 最大的 index 是 0) 但是最终 candidateReplica 是否是 replicas[0],取决于其MajorVersion 和 BinlogFormat ( 当 然 还 有isGenerallyValidAsCandidateReplica 和

IsBannedFromBeingCandidateReplica )

在官方文档 Discussion: recovering a dead master 中也有如下描述: Find the best replica to promote.

一种天真的方法是选择最新的副本, 但这可能并不总是正确的选择

A naive approach would be to pick the most up-to-date replica, but that may not always be the right choice.

最新的副本可能没有必要的配置来充当其他副本的主节点(例如, binlog 格式、MySQL 版本控制、复制过滤器等). 一味地推广最新的副本可能会丢失副本容量 It may so happen that the most up-to-date replica will not have the necessary configuration to act as master to other replicas (e.g. binlog format, MySQL versioning, replication filters and more). By blindly promoting the most up-to-date replica one may lose replica capacity. orchestrator 尝试提升将保留最多服务容量的副本.orchestrator attempts to

promote a replica that will retain the most serving capacity. 提升所述副本,接管其同级 Promote said replica, taking over its siblings.

Bring siblings up to date

可能的话,做第二阶段选举提升;如果可能的话,用户可能已经标记了要提升的特定服务器(见 register-candidate 命令)

Possibly, do a 2nd phase promotion; the user may have tagged specific servers to be promoted if possible (see register-candidate command).

但针对我们的场景,同一个集群不存在 Major 版本不同实例,Binlog\_format 也都 是 row 那 只 要 这 个 从 库 没 什 么 " 毛 病 ", 也 没 在 PromotionIgnoreHostnameFilters 中 , 那 基 本 上 replicas[0] 就 是 candidateReplica

那么继续看 GetCandidateReplica 剩下的代码

candidateReplica, aheadReplicas, equalReplicas, laterReplicas,
cannotReplicateReplicas, err = chooseCandidateReplica(replicas)

if err != nil { // 如果 chooseCandidateReplica 走到 if candidateReplica == nil { ,就会进入这个 if

 ${\tt return} \quad {\tt candidateReplica}, \quad {\tt aheadReplicas}, \quad {\tt equalReplicas}, \\ {\tt laterReplicas}, \quad {\tt cannotReplicateReplicas}, \quad {\tt err}$ 

if candidateReplica != nil {
 mostUpToDateReplica := replicas[0]

## // 这是有可能的

// 比如最常见版本是 5.6, 然后有一个 replica 是 5.7, 他是那个 most up-to-date 的从库,但它比 priorityMajorVersion 大. 他就不适合做 candidate if

 $candidate Replica.\ ExecBinlog Coordinates.\ Smaller Than (\&mostUp To Date Replica.\ ExecBinlog Coordinates) \ \{$ 

 $log.\ Warningf ("GetCandidateReplica: chosen replica: \%+v is behind most-up-to-date replica: \%+v", candidateReplica.\ Key, mostUpToDateReplica.\ Key)$ 

}

log. Debugf ("GetCandidateReplica: candidate:  $%+_{V}$ ahead: %d, late: %d, %d", candidateReplica. Key, equal: %d, break: len (aheadReplicas), len(equalReplicas), len(laterReplicas), len(cannotReplicateReplicas))

return candidateReplica, aheadReplicas, equalReplicas, laterReplicas, cannotReplicateReplicas, nil

```
}
现在再看 RegroupReplicasGTID
// RegroupReplicasGTID will choose a candidate replica of a given
instance, and take its siblings using GTID
func RegroupReplicasGTID(
   masterKey *InstanceKey, // 实参传进来的是 挂掉的旧主库
   returnReplicaEvenOnFailureToRegroup bool, // 实参传进来的是 true
   startReplicationOnCandidate bool, // 实参传进来的是 false
   onCandidateReplicaChosen func(*Instance), // 实参传进来的是 nil
    postponedFunctionsContainer *PostponedFunctionsContainer,
   postponeAllMatchOperations func(*Instance, bool) bool, // 实参传进
来的是 promotedReplicaIsIdeal 函数
) (
   lostReplicas [] (*Instance),
   movedReplicas [](*Instance),
   cannotReplicateReplicas [](*Instance),
   candidateReplica *Instance,
   err error,
) {
   var emptyReplicas [](*Instance)
   var unmovedReplicas [](*Instance)
   // candidateReplica 有可能==nil
   candidateReplica,
                      aheadReplicas,
                                      equalReplicas,
                                                      laterReplicas,
cannotReplicateReplicas, err := GetCandidateReplica(masterKey, true)
   // 如果 chooseCandidateReplica 走到 if candidateReplica == nil { ,就
会进入这个 if
       // Unable to find a candidate that will master others.
       // Instead, pick a (single) replica which is not banned.
   if err != nil {
       // returnReplicaEvenOnFailureToRegroup 实参传进来的是 true
       if !returnReplicaEvenOnFailureToRegroup {
           candidateReplica = nil
       return
                  emptyReplicas,
                                    emptyReplicas,
                                                      emptyReplicas,
candidateReplica, err
   }
   // onCandidateReplicaChosen 实参传进来的是 nil
   if onCandidateReplicaChosen != nil {
       onCandidateReplicaChosen(candidateReplica) // 所以走不到这里
```

```
// equalReplicas 和 laterReplicas 都可以做 candidateReplica 的从库,
所以放到 replicasToMove 里
   replicasToMove := append(equalReplicas, laterReplicas...)
   hasBestPromotionRule := true
   if candidateReplica != nil {
       // 迭代 replicasToMove
       for _, replica := range replicasToMove {
           // 比较 PromotionRule. 判断 candidateReplica 是不是用户
prefer 的
           if
replica. PromotionRule. BetterThan (candidateReplica. PromotionRule) {
               hasBestPromotionRule = false
       }
   moveGTIDFunc := func() error {
       log. Debugf ("RegroupReplicasGTID: working on %d replicas",
len(replicasToMove))
       // moves a list of replicas under another instance via GTID,
returning those replicas
       // that could not be moved (do not use GTID or had GTID errors)
                           unmovedReplicas,
       movedReplicas,
                                                 err,
moveReplicasViaGTID(replicasToMove,
                                                   candidateReplica,
postponedFunctionsContainer)
       unmovedReplicas = append(unmovedReplicas, aheadReplicas...)
       return log. Errore (err)
   }
   // 这个 postponeAllMatchOperations 就是 recoverDeadMaster 中定义的
promotedReplicaIsIdeal
   // 做一些判断, 但基本上就是看
                                            hasBestPromotionRule 和
candidateReplica 的 promotion rule 是不是 MustNotPromoteRule.
candidateReplica 就是理想的,那 moveGTIDFunc 就放到异步推迟执行
             postponedFunctionsContainer
                                              !=
   if
                                                       nil
                                                                  &&
postponeAllMatchOperations
                                                   nil
                                                                  &&
postponeAllMatchOperations(candidateReplica, hasBestPromotionRule) {
       postponedFunctionsContainer.AddPostponedFunction(moveGTIDFunc,
fmt.Sprintf("regroup-replicas-gtid %+v", candidateReplica.Key))
   } else {
   // 否则同步执行
       err = moveGTIDFunc()
```

// 我没太看懂上面那个 if else, 除了 canidateReplica 恰好是 prefer 的那个时多输出一个日志义务外,和 else 时有啥区别吗?

if startReplicationOnCandidate { // 实参传进来的是 false. 在 DeadMaster 场景, 这里不能传 true, 因为 StartReplication 会调用 MaybeEnableSemiSyncReplica, 而后者需要连接 old master

// 但是 old master 已经挂了所以肯定连不上, 于是这里出现 error 直接 return 了,后面真正的 start slave 是没机会执行的

StartReplication(&candidateReplica.Key)

}

log.Debugf("RegroupReplicasGTID: done")

AuditOperation("regroup-replicas-gtid", masterKey, fmt.Sprintf("regrouped replicas of %+v via GTID; promoted %+v", \*masterKey, candidateReplica.Key))

 $return \quad unmoved Replicas, \quad moved Replicas, \quad cannot Replicate Replicas, \\ candidate Replica, \quad err$ 

所以 RegroupReplicasGTID

选了个 candidateReplica 出来,并给其他 replica 归了类

这个 candidateReplica 不一定是最终的主库, 只是它的 ExecBinlogCoordinates 大

通过 moveReplicasViaGTID ,将其他的 replica(除了 aheadReplicas 和 cannotReplicateReplicas )都 change master 到了 candidateReplica

至此 RegroupReplicasGTID 工作完成了, 剩下的工作可以交换给recoverDeadMaster了, 就是recoverDeadMaster 主要做了几件事中的最后两步操作

recoverDeadMaster 主要做了几件事

GetMasterRecoveryType,确定到底用什么方式恢复,是基于 GTID?PseudoGTID?还是 BinlogServer?

重组拓扑,我们的案例是使用 RegroupReplicasGTID. 但这里有一个问题,可能现在我们的新主库并不是我们"期望"的实例,就是说之所以选他做主库可能是因为他有最全的日志。但不是我们设置的 prefer 的所以通过一个闭包promotedReplicaIsIdeal 去做了判断和标记

如果存在 lostReplicas ,并且开启了 DetachLostReplicasAfterMasterFailover,那么会并行的对所有 lostReplicas 执行 DetachReplicaMasterHost. 其实就是执行 change master to master\_host='// {host}'

如果当前选举的 new master 不是我们 prefer 的实例, 重组拓扑, 用 prefer 做新主库

DelayMasterPromotionIfSQLThreadNotUpToDate 有 bug

根据 Orchestrator Failover 过程源码分析-II

没有在 recoverDeadMaster 和 checkAndRecoverDeadMaster 中看到任何代码执行了 start slave sql\_thread

那在 checkAndRecoverDeadMaster 执行到这里时,不是肯定会超时吗

if config.Config.DelayMasterPromotionIfSQLThreadNotUpToDate
&& !promotedReplica.SQLThreadUpToDate() {

AuditTopologyRecovery(topologyRecovery,

fmt.Sprintf("DelayMasterPromotionIfSQLThreadNotUpToDate: waiting for SQL thread on %+v", promotedReplica.Key))

if \_\_, err :=

 $fmt. \ Errorf ("DelayMasterPromotionIfSQLThreadNotUpToDate error: \%+v", err)$ 

AuditTopologyRecovery(topologyRecovery,

 $\label{lem:condition} $$\operatorname{fmt.Sprintf}("DelayMasterPromotionIfSQLThreadNotUpToDate: SQL thread caught up on $\%+v"$, promotedReplica.Key))$$ 

实际测试确实有问题.在issue https://github.com/openark/orchestrator/issues/1430中,我们内部分支也 修复了这个bug,我的同事也在issue中给出了我的解决办法。

总结

图片

点击可放图

本文关键字: #MySQL 高可用# #Orchestrator#

文章推荐:

技术分享 | Orchestrator Failover 过程源码分析-I

技术分享 | Orchestrator Failover 过程源码分析-II

技术分享 | 大数据量更新,回滚效率提升方法

故障分析 | 填坑 TaskMax

关于 SQLE

爱可生开源社区的 SQLE 是一款面向数据库使用者和管理者,支持多场景审核,支持标准化上线流程,原生支持 MySQL 审核且数据库类型可扩展的 SQL 审核工具。

SQLE 获取

类型 地址

版本库 https://github.com/actiontech/sqle

文档 https://actiontech.github.io/sqle-docs-cn/

发布信息 https://github.com/actiontech/sqle/releases

数据审核插件开发文档 https://actiontech.github.io/sqle-docs-

 $\verb|cn/3.modules/3.7_auditplugin/auditplugin_development.|| \verb|html||$ 

更多关于 SQLE 的信息和交流,请加入官方 QQ 交流群: 637150065...