

Gdevops
Global DevOps Summit

全球敏捷运维峰会

大模型与向量数据库：敏捷运维的创新引擎

演讲人：爱可生 苏鹏



公司概况



爱可生，国内开源数据库服务及数据库平台解决方案的龙头公司，致力于数据库领域，为客户提供企业级的数据库全生态软件产品和服务。



产品主要涵盖：多数据库自动化运维管理平台（云树DMP）、数据库云服务平台（云树RDS）、分布式数据库（云树Shard）、SQL审核平台（SQLE）、向量数据库（TensorDB）等软件产品，以及多中心容灾建设、数据迁移等解决方案。



爱可生成立于2003年，总部和研发中心位于上海，下设北京、深圳等分公司，拥有**15+**年大型系统平台运维经验，位列全球**TOP10**规模的系统建设及运维经验、**1000+**运维项目经验。



近3年私有云市场MySQL产品&运维服务领导地位，得到行业客户的广泛认可，拥有多家世界500强客户及大型银行客户，在金融行业树立标杆地位。





开源生态



爱可生开源社区

发消息



爱可生开源社区，提供稳定的MySQL企业级开源工具及服务，每年1024开源一款优良组件，并持续运营维护。

702篇原创内容 52个朋友关注

📺 视频号: simplelogic

爱可生开源社区提供的服务

技术干货

8.0 新特性

故障分析

技术分享

公开课

公开演讲

技术专栏

图解MySQL

一问一实验

SQL 调优

详解 Prometheus

ClickHouse 系列

社区信息

开源产品

社区活动

社区官网

关于爱可生



技术文章

累计1000+篇

每日一更



《大智小技》

共推出四册

总发送数量破 6000+





社区热度

平均阅读量

1000+

粉丝量破

13000+





数据库解决方案直签标杆客户案例

十五年磨砺，厚积薄发

400+大B用户

45世界五百强

金融行业				广电通信行业		其他行业		
银行	互金	保险	证券	广电	通信	零售	政企	制造
中国工商银行 中国农业银行 中国银行 中国人民银行 招商银行 兴业银行 浦发银行 平安银行 华夏银行 中信银行 泰隆银行 中国银联	光大集团 兴业数金 京东金融 甜橙金融 翼支付 万达金融控股集团 海风消费金融 捷元 拾财贷 宜人贷 欧治云商 BCS长银58	中国人民保险 太平洋保险 中国人寿 中国太平 阳光保险 中国大地财险 天安财险 中宏保险 百年人寿 永诚保险 交银康联人寿 FWD富卫 前海人寿 爱星保德信	中央结算公司 光大证券 兴业证券 中国外汇交易中心 CSDC中国结算 证通股份 深圳证券交易所 中国信托登记有限责任公司 全国中小企业股份转让系统	国家广播电视总局 CCTV BTV北京电视台 SMG上海广播电视台 JSCN江苏有线 GRT广东广播电视台 NBS南京广播电视台 咪咕 数字电视 华数 新媒股份	中国移动 中国电信 中国联通 亞太電信 france telecom ZTE中兴 FiberHome HUAWEI H3C	绿地集团 Yum China LI-NING 优速快递 华住 Disney迪士尼 STARBUCKS STARBUCKS STARBUCKS STARBUCKS STARBUCKS	NARI南瑞集团 重庆市气象局 中国航信 国家电网公司 广州地铁 中国南方航空 厦门航空 国家能源集团 万达集团	上汽集团 COSIC中国航天科工集团 中国航空工业集团公司 中国航天科技集团公司 中国航发 ADIENT 捷瑶安适拓 oppo lenovo 金风科技



DBA的常见困扰

业务增长太快，数据库该如何扩展，读写分离、分库分表怎么选？多大的表该做拆分，怎么拆呢？数据咋迁移呢？

Oracle是去掉了，用了一堆开源库，运维太麻烦了。

开源数据库占比越来越大，怎样才能快速掌握它们的最佳实践呢？

前期没有做标准化，现在数据量增长太快，运维效率下降，问题越来越多。


网上流传的双主架构，数据经常不一致，复制老中断，该咋整？

开发drop库了，恢复起来太费劲，有没有快速恢复的方案？

安全扫描又来，数据库又要升级，有没有批量自动化的升级方案？


业务要用的数据库种类太多了，MySQL、Redis、MongoDB、PostgreSQL、TiDB，能不能统一维护起来？

业务抱怨数据库运行缓慢，没有足够信息采集，该如何诊断？





SQL质量管理存在问题：发布不规范，事前无控制，事后少跟踪





云树DMP — 多数据库自动化运维管理平台

云树DMP (自动化运维管理平台)

管理区

主机管理

实例管理

监控告警

备份恢复

读写分离


分库分表

用户管理




灾备管理

日志管理


SQL审核



管理节点集群



基础资源



裸金属



虚拟化



容器



公有云主机



系统运维的稳定性从规范化的部署开始



适配计算资源

裸机资源
虚拟机资源



运维效率

分钟级别交付
支持批量安装部署



标准化交付

标准架构
标准配置
标准模板
标准接管



数据库类型

MySQL
Redis
MongoDB
TiDB
Oracle

批量接管数据库实例

本地文件 • 选择文件 未选择任何文件

并发数 • 30

上线检查 • ☐ 已阅读上线检查规范
接管数据库实例前,请先阅读上线检查规范

关闭 下载接管模板 保存

整组安装数据库组

数据库组名 • mysql-group1

数据库管理用户 • root

数据库管理用户密码 • ***** 生成

端口号 • 3306

sip • 请选择一个sip

安装压缩包 • mysql-5.7.25-linux-glibc2.12-x86_64.tar.gz

CPU使用核数 • 请输入CPU使用核数


内存(MB) • 请输入内存

安装架构 • 请选择一个安装架构

- 一主两从半同步
- 一主两从组复制
- 一主一从半同步

开始部署 执行

备份、转储、恢复、演练一套完整闭环的备份恢复系统



编排

自动编排所有备份任务
发送每天编排报表
异常编排任务告警

备份

全量/增量
物理备份/Binglog 备份
备份自动回收

转储

ftp、磁盘、带库
自动转储，故障无忧
NBU/S3 备份对接

恢复演练

自动恢复演练
指定时间点恢复
故障恢复预测


灾备报告

展示RTO、RPO
备份数据有效性验证



定时健康巡检，快速诊断数据库，将故障隐患扼杀在摇篮里


健康诊断报告 (自动化定时 + 手工实时)



库表检查



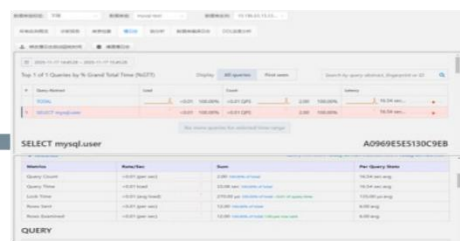
错误日志 & DDL 进度分析



图形化锁分析



慢日志分析



连接分析

分析当前连接执行的SQL情况, 找出运行时间较长的连接, kill 高负载的连接

磁盘空间分析

图形化锁分析

慢日志分析

库表检查

检查出不合理的库表设计, 无主键表影响同步性能; 冗余索引影响插入性能; 主键uuid 影响插入性能

健康报告

多维度掌握数据库的健康情况



成千实例规模，成万监控指标，实时指标展示，告警异常及时



监控数据采集

数据库探活

可用性、资源、性能、容量指标采集

高可用架构探测

自动发现监控对象，无需额外配置操作



可扩展

采用云原生监控构，支持监控数据

sharding，可监控上万个监控指标；


采用错峰采集机制，减小被监控对象的负载压力



告警处理

升级变更期间可设置告警静默，避免无效告警


告警通道可灵活配置，支持邮件、企业微信、短信平台等告警通道





SQL治理需要考虑SQL全生命周期

软件生命周期




问题越早解决成本越低!

第三方统计数据显示: 49.4%的数据库故障是由于SQL不规范、效率低等问题引起



标准发布: 上线工单变更发布标准化, 杜绝问题SQL流向生产

变更SQL上线发布流程



审核结果 审核通过至100% 审核结果评分100

下载审核报告 下载SQL语句 是否去重

审核状态: 请选择要搜索的 审核状态 执行状态: 请选择要搜索的 执行状态 审核结果: 请选择要搜索的 审核结果

重置 搜索

序号	审核状态	审核结果	执行语句	执行状态	执行结果	回滚语句 (仅提示, 不支持执行回滚)	说明
1	审核通过		select name from test where id =1;	准备执行			

1 10条/页

工单进度

- 操作时间:2022-03-21 16:55:14 操作人:admin admin创建了当前工单
- 操作时间:2022-03-21 17:45:14 操作人:demo_user demo_user通过了当前工单的审核
- 操作时间:2022-03-21 17:45:24 操作人:admin admin通过了当前工单的审核
- 操作时间:-- 操作人:--

立即上线 立即上线 撤回

只能在运维时间之内执行立即上线,当前数据库的运维时间为: 00:00-06:00

发布效率提升, 发布留痕

变更SQL一键执行上线, 提升发布效率

手动上线/定时上线

发布留痕, 可追溯

建立标准化发布流程

所有发布必须通过平台执行,

线下人情上线减少100%, 问题

SQL引起的性能问题减少60%




多种模式发布，批量上线，满足不同场景上线诉求

批量上线需求，涉及多个数据库

分环境域上线场景：生产环境/预发布环境上线

分区域上线场景：国内/国外环境



工单基本信息 (Ticket Basic Information)

* 工单名称: dingdan_0009

工单描述: (订单系统0009数据)

* 工单模式: 新增SQL 变更SQL

* 数据库: test 数据库: test2 数据库: test3

* 数据库: test2 数据库: test3 数据库: test3

* 数据库: test3 数据库: test3 数据库: test3

+ 添加数据库

测试数据库连接性

test test2 test3

选择部署SQL语句上传方式: ☒ 输入SQL语句 ☐ 上传SQL文件 ☐ 上传MySQL的XML文件

* SQL语句: 1 /* input your sql */

工单进度 (Ticket Progress)

操作时间: 2022-09-16 10:49:34 操作人: admin admin创建了当前工单

操作时间: 2022-09-16 12:30:24 操作人: admin admin通过了当前工单的审核


操作时间: -- 操作人: --

[批量立即上线](#)

数据库	状态	上线开始时间	上线结束时间	定时上线时间	待操作人	审核通过率	审核结果评分	操作
mysql-1	定时上线			2022-09-16T21:00:00+08:00	admin	100%	100	立即上线 定时上线 取消定时上线
mysql-2	待上线				admin	100%	100	立即上线 定时上线



事后SQL审核



TOP SQL采集审核

- 1.根据采集周期SQLE定期获取数据库TOP SQL语句
- 2.使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

慢日志采集审核

- 1.SQLE实时获取数据库慢日志SQL语句
- 2.定期审核：使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

审计日志采集审核

- 1.SQLE通过客户端程序实时获取数据库慢日志SQL语句
- 2.定期审核：使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

库表元数据审核

- 1.根据采集周期SQLE定期获取数据库库表元数据信息
- 2.使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

云数据库审核

- 1.SQLE调用RDS的慢日志、审计日志等API获取运行SQL信息
- 2.SQLE使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。



SQLE：多元异构数据库SQL管理方案




目前还存在什么问题？

故障定位后需要大量人工操作

多表关联SQL开发复杂

SQL审核规则多样



刚上手一款新的数据库不知道该如排查问题

如何对SQL进行优化观点不一


现场交付人工成本高

```

->tail -f mysql_slow_log.1 | grep Query time
# Query_time: 0.000715 Lock_time: 0.000056 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000583 Lock_time: 0.000071 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000353 Lock_time: 0.000054 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000725 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000302 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000327 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.001899 Lock_time: 0.000045 Rows_sent: 1 Rows_examined: 1731 Rows_affected: 0
# Query_time: 0.000693 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000318 Lock_time: 0.000055 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000367 Lock_time: 0.000053 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000682 Lock_time: 0.000053 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000301 Lock_time: 0.000056 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000321 Lock_time: 0.000058 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000683 Lock_time: 0.000050 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.002353 Lock_time: 0.000049 Rows_sent: 1 Rows_examined: 1727 Rows_affected: 0
# Query_time: 0.000307 Lock_time: 0.000053 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000327 Lock_time: 0.000057 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000705 Lock_time: 0.000052 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000312 Lock_time: 0.000049 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000315 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.001937 Lock_time: 0.000044 Rows_sent: 1 Rows_examined: 1723 Rows_affected: 0
# Query_time: 0.000701 Lock_time: 0.000059 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000296 Lock_time: 0.000052 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000325 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000681 Lock_time: 0.000051 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
    
```



目前存在什么问题？



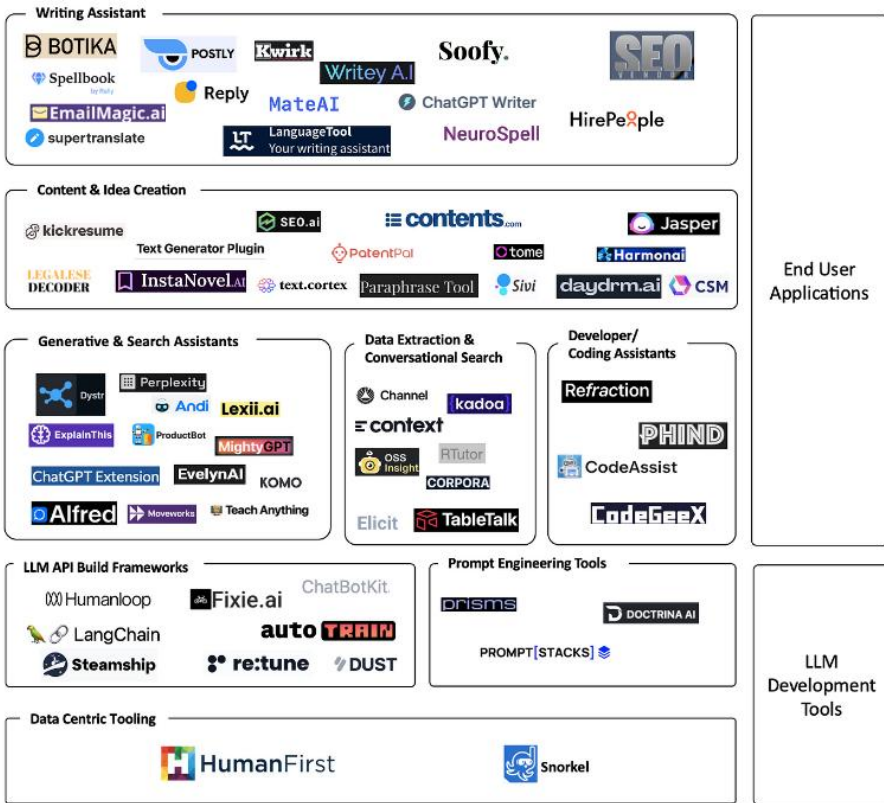


大模型正在重构所有行业

入局大模型的中国企业/科研院所及产品汇总

企业类型	企业/创始人名称	大模型及相关产品
互联网公司	百度	“文心”大模型/文心一言
	阿里	“通义”大模型/通义千问
	腾讯	“混元”大模型/混元助手
	华为	“盘古”大模型
	字节跳动	飞书My AI
	京东	Chat JD
	知乎	“知海图AI”大模型（与面壁科技合作）
	昆仑万维	“天工”大语言模型
	麒麟合盛	“天燕”大模型
	360	360智脑
AI公司	网易	“玉言”预训练大模型
	小米	正在研发，还未公布
	金山办公	WPS AI（大模型由MiniMax提供）
	商汤科技	日日新SenseNova/商量、秒画、如影
	科大讯飞	“讯飞星火”认知大模型
	出门问问	“序列猴子”大模型/奇妙文、言之画
	智谱AI（清华大学技术成果转化）	ChatGLM
	澜舟科技	“孟子MChat”大模型
	毫末智行	“DriveGPT”自动驾驶生成式大模型
	竹间智能	“魔力写作”大模型
初创公司	MiniMax	自研多模态大模型/Glow
	面壁科技	“知海图AI”大模型（与知乎合作）
	聆心智能	超拟人大模型/AI乌托邦
	元语科技	“元语ChatYuan”对话大模型
	云从科技	“行业精灵”大模型研发项目（募资中）
	达观数据	“曹植”大语言模型
	王慧文（美团联合创始人）	光年之外（公司名称）
	李开复（创新工场董事长）	Project AI2.0
	王小川（搜狗公司创始人）	百川智能（公司名称）
	周伯文（京东AI掌门人）	街远科技（公司名称）
科研院所	复旦大学邵锦朋教授团队	“MOSS”对话式大型语言模型
	中国科学院自动化研究所	“紫东太初”多模态大模型
	上海人工智能实验室	“风乌”天气预报大模型
	北京智源人工智能研究院	“悟道2.0”预训练大模型
教育行业	哈尔滨工业大学	“活字”对话大模型
	网易有道	“子曰”大模型
	学而思	“MathGPT”数学大模型

资料来源：《财经》记者整理





大模型的局限性

大量私域数据


虽然大模型具有强大的语言理解和生成能力，但由于它们并未接触过企业的私域数据和特定业务场景，因此，它们无法完全满足企业实际需求，也无法优化企业的具体业务流程。这就使得企业在利用这些模型时可能会遇到一些挑战和困难。

新增海量数据

由于大模型的训练过程需要大量的计算资源和时间，这使得大模型往往无法及时吸收和学习到企业最新产生的数据。这就意味着，尽管企业持续产生的数据具有很高的价值，但由于无法及时纳入大模型的训练中，这部分价值可能会被忽视或遗漏。





大模型+向量数据库






如何实现非结构化数据的搜索



向量数据库



query




大模型+向量数据库



+



+



机器




人工

取代


TensorDB-爱可生向量数据库企业版软件

TensorDB 实现了超大规模向量型数据的高效组织，可以有效支撑时变环境下的向量数据快速比对，面向复杂场景下的实体分析与关系推断，TensorDB 克服了 AI 领多样化应用面临的非结构化数据管理与处理分析困难，提升了数据库异构融合能力。TensorDB 具有极高的并发检索性能，支持卓越的水平拓展能力，并提供满足多元业务场景下的高可用需求。TensorDB 致力于为用户提供一站式非结构化数据的检索与存储解决方案。





ChatDBA: 大模型+私域知识库赋能智能运维



如果我的MySQL cpu使用率高, 该如何排查



1. 使用top命令查看服务器整体的负载情况, 确定是MySQL进程CPU使用率高后, 进行下一步分析。[引用1](#)
2. 登录MySQL, 执行show processlist命令查看线程情况, 关注Time、State、Info三个指标, 分析是否有某些SQL执行很慢。[引用2](#)
3. 使用pt-query-digest工具对慢查询日志进行分析, 找出慢查询。[引用3](#)
4. 找到问题SQL, 可以使用explain命令查看SQL的执行计划, 也可以优化SQL来解决问题。[引用4](#)

种情况的分析方法。
5.2 分析方法
5.2.1 top查看进程状态

top命令可以查看服务器整体的负载情况, 既然是CPU使用率高, 我们就关注CPU指标, 确定是MySQL进程CPU使用率高后, 进行下一步分析。

5.2.2 show processlist

登录MySQL, 执行show processlist命令查看线程情况:

```
mysql> show processlist;
```

```
+-----+-----+-----+-----+-----+-----+-----+
| Id | User | Host | db | Command | Time | State | Info |
+-----+-----+-----+-----+-----+-----+-----+
| 1 | root | 127.0.0.1 | mysql | SHOW PROCESSLIST | 0 | Sleeping | show processlist; |
+-----+-----+-----+-----+-----+-----+-----+
```



如何弥补文档切片造成的信息丢失？ 文本相似度很难度量提问和文档切片的相关性？

1. mysqlbackup
的使用规范

1.1 参数介绍

...

1.2 常见故障

...

2. xtrabackup

的使用规范

2.1 参数介绍

...

2.2 常见故障

...

错误切片



介绍

...

2.2 常见
故障

...

提问: 如何备份MySQL数据




相似的文档切片: MySQL可以通过
mysqldump进行数据导出



如何弥补文档切片造成的信息丢失？

对文档切片进行预处理，补齐关键信息。例如：





提问: 如何备份MySQL数据


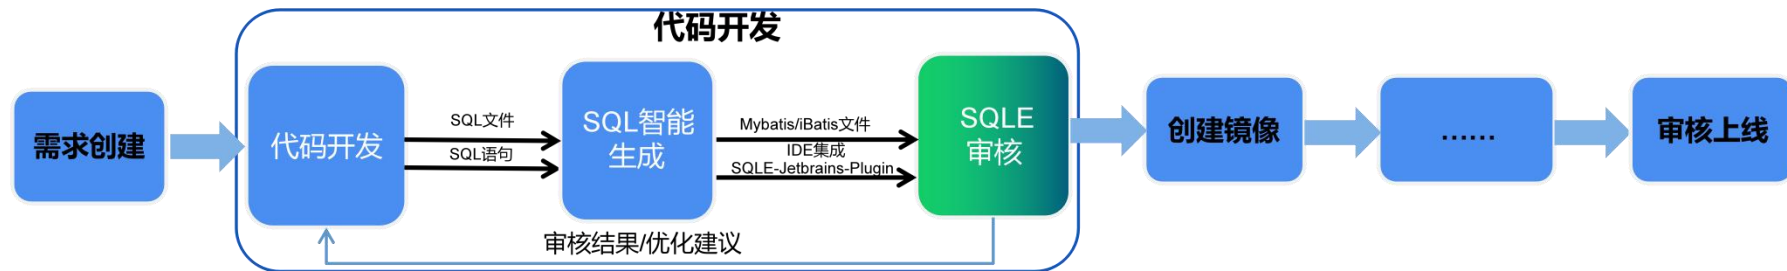
通过大模型进行[假设性回答]: 可以通过rman对MySQL的数据进行备份, 也可以 导出部分数据

文档切片: MySQL可以通过mysqldump进行数据导出

通过[假设性回答]与[文档切片]间的相似性, 来提高[提问]与[文档切片]的关系




SQL生成到审核优化的全流程智能控制






SQL生成到审核优化的全流程智能控制



- 作为一个二分类的任务，缺少推理流程导致精度较低。
- 大模型对SQL的执行计划理解有偏差
- 对于规则理解有误



SQL生成到审核优化的全流程智能控制






大模型+向量数据库



+



+



- 结果可信
- 自动执行
- 反馈优化

+

- 更多优质的数据
- 更多工程的优化
- 更多模型的认知

Gdevops
Global DevOps Summit

全球敏捷运维峰会

THANK YOU !

