

TensorDB

用GPU检索的向量数据库

上海爱可生信息技术股份有限公司 阎虎青

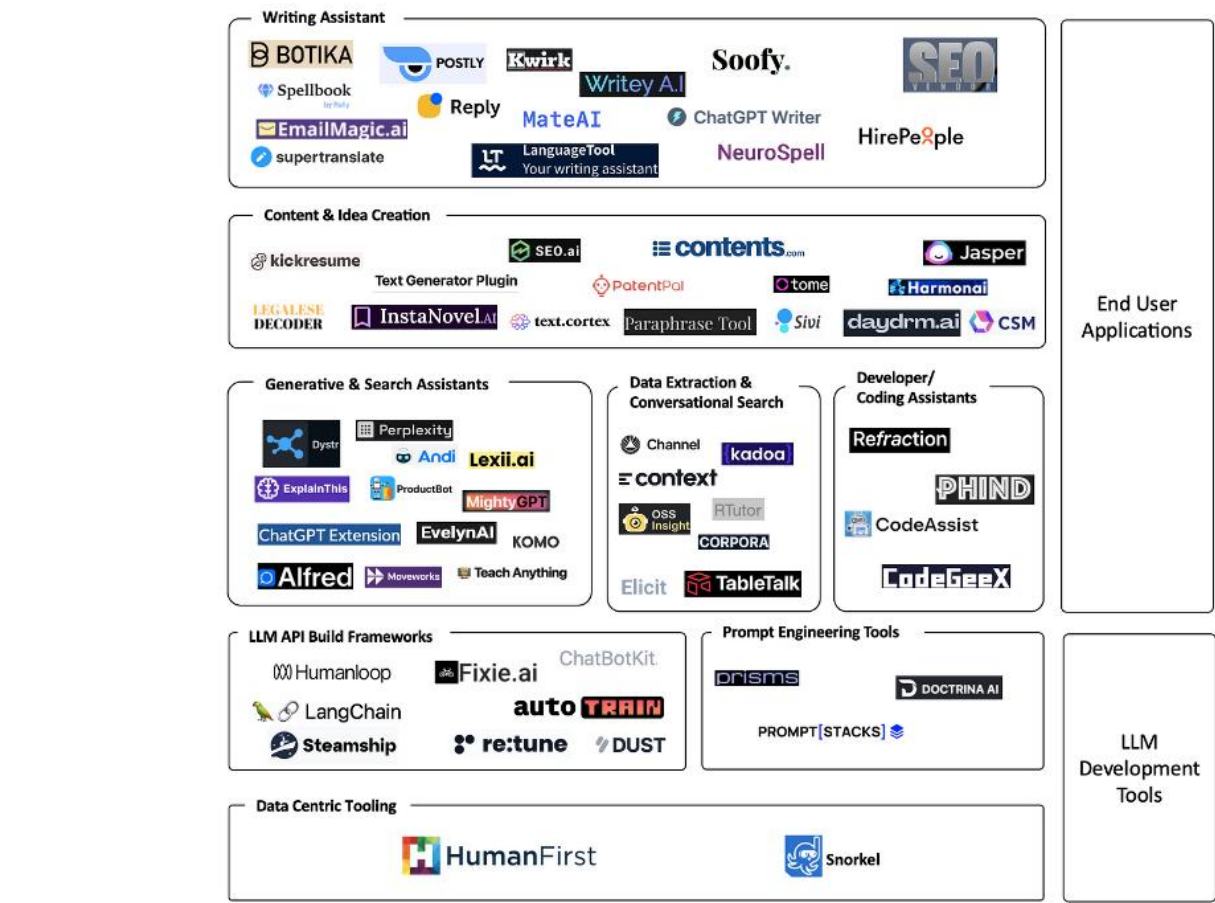
大模型正在占领世界



入局大模型的中国企业/科研院所及产品汇总

企业类型	企业/创始人名称	大模型及相关产品
互联网公司	百度	“文心”大模型/文心一言
	阿里	“通义”大模型/通义千问
	腾讯	“混元”大模型/混元助手
	华为	“盘古”大模型
	字节跳动	飞书My AI
	京东	Chat JD
	知乎	“知海图AI”大模型（与面壁科技合作）
	昆仑万维	“天工”大语言模型
	麒麟合盛	“天燕”大模型
	360	360智脑
AI公司	网易	“玉言”预训练大模型
	小米	正在研发，还未公布
	金山办公	WPS AI（大模型由MiniMax提供）
	商汤科技	日日新SenseNova/商量、秒画、如影
	科大讯飞	“讯飞星火”认知大模型
	出门问问	“序列猴子”大模型/奇妙文、言之画
	智谱AI（清华大学技术成果转化）	ChatGLM
	澜舟科技	“孟子MChat”大模型
	毫末智行	“DriveGPT”自动驾驶生成式大模型
	竹间智能	“魔力写作”大模型
初创公司	MiniMax	自研多模态大模型/Glow
	面壁科技	“知海图AI”大模型（与知乎合作）
	聆心智能	超拟人大模型/AI乌托邦
	元语科技	“元语ChatYuan”对话大模型
	云从科技	“行业精灵”大模型研发项目（募集中）
	达观数据	“曹植”大语言模型
	王慧文（美团联合创始人）	光年之外（公司名称）
	李开复（创新工场董事长）	Project AI2.0
	王小川（搜狗公司创始人）	百川智能（公司名称）
	周伯文（前京东AI掌门人）	街远科技（公司名称）
科研院所	复旦大学邱锡朋教授团队	“MOSS”对话式大型语言模型
	中国科学院自动化研究所	“紫东太初”多模态大模型
	上海人工智能实验室	“风乌”天气预报大模型
	北京智源人工智能研究院	“悟道2.0”预训练大模型
教育行业	哈尔滨工业大学	“活字”对话大模型
	网易有道	“子曰”大模型
	学而思	“MathGPT”数学大模型

资料来源：《财经》记者整理



1

Text2SQL

2

Copilot

3

Text2Media

大模型的局限性

幻觉问题

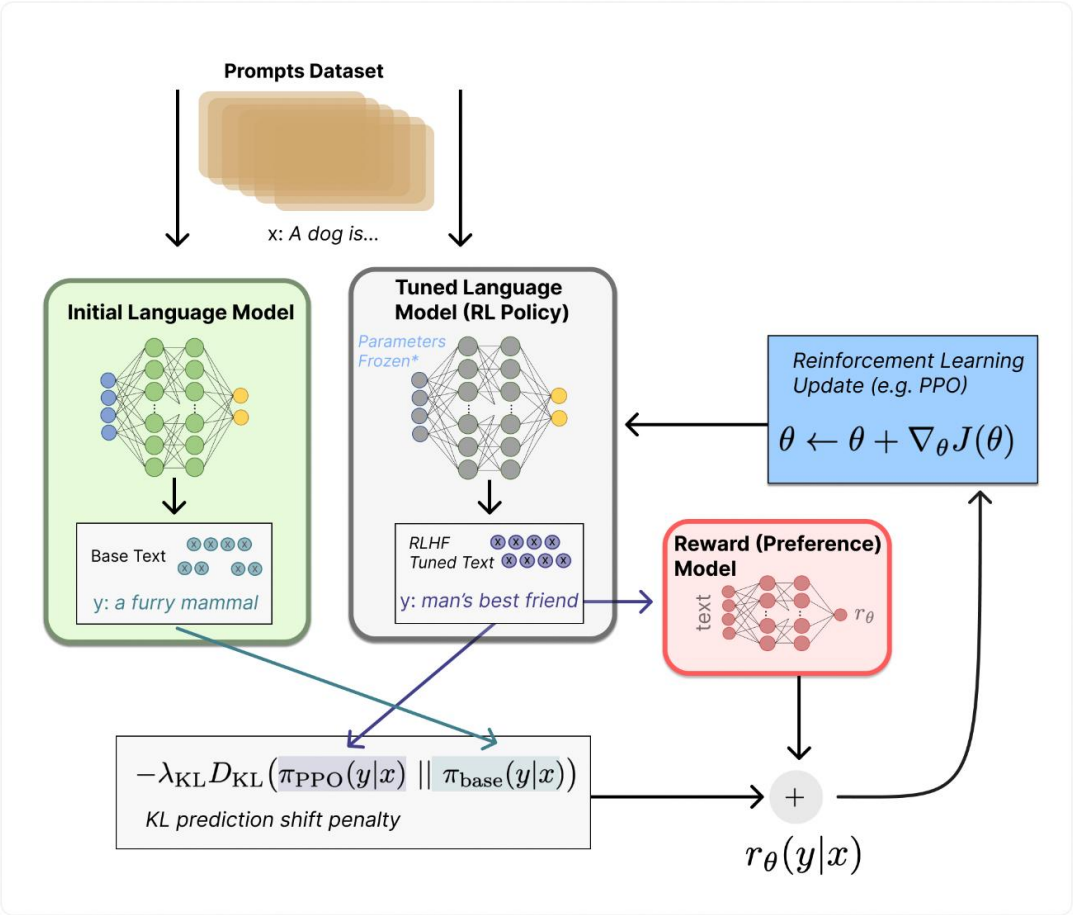
大量私域数据

新增海量数据




大模型的局限性如何解决

模型微调



基于检索的大模型



非结构化数据正在迅猛增长

int, float,
string, ...

text

json

image
video
audio

domain specific

0 1 2 3 4
5 6 7 8 9

e π



ABCDEFGH

2021.04.10

Abstract

Bigtable is a distributed storage system for managing structured data that is designed to scale to a very large size: petabytes of data across thousands of commodity servers. Many projects at Google store data in Bigtable, including web indexing, Google Earth, and Google Finance. These applications place very different demands on Bigtable, both in terms of data size (from URLs to web pages to satellite imagery) and latency requirements (from backend bulk processing to real-time data serving). Despite these varied demands, Bigtable has successfully provided a flexible, high-performance solution for all of these Google products. In this paper we describe the simple data model provided by Bigtable, which gives clients dynamic control over data layout and format, and we describe the design and implementation of Bigtable.

```
{
  "firstName": "John",
  "lastName": "Smith",
  "isAlive": true,
  "age": 27,
  "address": {
    "streetAddress": "21 2nd Street",
    "city": "New York",
    "state": "NY",
    "postalCode": "10021-3100"
  },
  "phoneNumbers": [
    {
      "type": "home",
      "number": "212 555-1234"
    },
    {
      "type": "office",
      "number": "646 555-4567"
    }
  ],
  "children": [],
  "spouse": null
}
```






Structured data




Unstructured data


机器理解非结构化数据

机器理解数据



AI模型 / 编码手段






什么是向量数据库

在常见的 AI 场景中，例如以图搜图，视频推荐或者文本检索，需要存储的不是仅仅是图片，视频或者文本片段等非结构化数据，还要存储通过 **AI 模型提取出来的高维向量**，这些高维向量类似于数学领域中的坐标系的点，标识了不同数据之间的关系，通过向量可以实现数据之间高效的相似性比对，来赋能相应的业务场景。**向量数据库就是可以使用户更加便捷的访问，检索，管理，组织向量数据的一种数据库。**


向量化表示




卷积神经网络




向量空间




向量化表示



卷积神经网络




向量空间




向量化表示





卷积神经网络



向量空间





向量化表示





如何实现非结构化数据搜索

卷积神经网络



向量数据库

向量空间



query



result


GPU能做什么

CPU



- * Low compute density
- * Complex control logic
- * Large caches (L1\$/L2\$, etc.)
- * Optimized for serial operations
 - Fewer execution units (ALUs)
 - Higher clock speeds
- * Shallow pipelines (<30 stages)
- * Low Latency Tolerance
- * Newer CPUs have more parallelism

GPU



- * High compute density
- * High Computations per Memory Access
- * Built for parallel operations
 - Many parallel execution units (ALUs)
 - Graphics is the best known case of parallelism
- * Deep pipelines (hundreds of stages)
- * High Throughput
- * High Latency Tolerance
- * Newer GPUs:
 - Better flow control logic (becoming more CPU-like)
 - Scatter/Gather Memory Access
 - Don't have one-way pipelines anymore

GPU长啥样




Figure 6. GA100 Full GPU with 128 SMs (A100 Tensor Core GPU has 108 SMs)

GPU长啥样




Figure 7. GA100 Streaming Multiprocessor (SM)

GPU加速距离计算


$$D = \begin{pmatrix} A_{0,0} & A_{0,1} & A_{0,2} & A_{0,3} \\ A_{1,0} & A_{1,1} & A_{1,2} & A_{1,3} \\ A_{2,0} & A_{2,1} & A_{2,2} & A_{2,3} \\ A_{3,0} & A_{3,1} & A_{3,2} & A_{3,3} \end{pmatrix} \begin{pmatrix} B_{0,0} & B_{0,1} & B_{0,2} & B_{0,3} \\ B_{1,0} & B_{1,1} & B_{1,2} & B_{1,3} \\ B_{2,0} & B_{2,1} & B_{2,2} & B_{2,3} \\ B_{3,0} & B_{3,1} & B_{3,2} & B_{3,3} \end{pmatrix} + \begin{pmatrix} C_{0,0} & C_{0,1} & C_{0,2} & C_{0,3} \\ C_{1,0} & C_{1,1} & C_{1,2} & C_{1,3} \\ C_{2,0} & C_{2,1} & C_{2,2} & C_{2,3} \\ C_{3,0} & C_{3,1} & C_{3,2} & C_{3,3} \end{pmatrix}$$

FP16 or FP32 FP16 FP16 FP16 or FP32

GPU加速排序



GPU加速排序




shfl_xor (1) //L=1

shfl_xor (3) //L=2
shfl_xor (1)


shfl_xor (7) //L=4
shfl_xor (2)
shfl_xor (1)

GPU加速排序





shfl_xor (15) //L=8
shfl_xor (4)
shfl_xor (2)
shfl_xor (1)


GPU加速排序



shfl_xor (31) //L=16
shfl_xor (8)
shfl_xor (4)
shfl_xor (2)
shfl_xor (1)

TensorDB[®] — 爱可生向量数据库企业版软件






- NVIDIA GPU向量计算加速
- 单机多卡，多机多卡
- TensorDB与**国产化GPU**（如华为昇腾，天数智芯，海光等）进行深度适配



基于大模型+向量数据库的智能运维解决方案（类知识库）



技术方案:

1. 数据清洗: 将原有知识库文档进行预处理, 重新修整文档逻辑
2. 文档切分: 采用基于摘要的上下文文本语义分割方法对文档进行拆分
3. 向量检索: 基于TensorDB构建索引, 实现高效向量相似性检索
4. LLM总结: 采用开源大模型, 例如ChatGLM, LLaMA等模型进行结果的总结输出

基于大模型+向量数据库的智能运维解决方案（类知识库）




MySQL报错: Too many open files, 经常重启有什么可能的原因?

可能的原因是大量的 `order by` 语句产生了临时文件, 导致打开文件数量过多。此外, 还需要检查 `ulimit open files` 设置、MySQL的`innodb_open_files`配置、`idb`文件数量、链接数量监控、临时表和临时表空间配置等方面。同时, 可以通过观察 `slow log` 记录的慢查询和临时文件过多的情况来进一步诊断问题。解决方案包括统一数据类型、设置 `internal_tmp_mem_storage_engine=MEMORY`、设置 `innodb_open_files=102400`、开启 `coredump`、定时任务监控等。

GPT4: 为了解决这个问题, 你可以考虑以下步骤:

- 1.增加操作系统的文件描述符限制。
- 2.增加MySQL的`open_files_limit`。
- 3.检查并调整`table_open_cache`的值。
- 4.考虑更改数据存储引擎（例如从MyISAM迁移到InnoDB）。
- 5.优化数据库设计, 减少不必要的表。
- 6.定期检查并清理旧的日志文件。



技术即服务

Technology as a Service

谢谢观看！

