

爱可生向量数据库 TensorDB+大模型的应用构建

上海爱可生信息技术股份有限公司

目录

1

公司介绍

2

向量数据库的概念

3

大模型的局限性

4

解决方案

5

优化思路

01

公司介绍

公司概况



爱可生，国内开源数据库服务及数据库平台解决方案的龙头公司，致力于数据库领域，为客户提供企业级的数据库全生态软件产品和服务。



产品主要涵盖：多数据库自动化运维管理平台（云树DMP）、数据库云服务平台（云树RDS）、分布式数据库（云树Shard）、SQL审核平台（SQLE）、数据同步工具（DTS）等软件产品，以及多中心容灾建设、数据迁移等解决方案。



爱可生成立于2003年，总部和研发中心位于上海，下设北京、深圳等分公司，拥有**15+**年大型系统平台运维经验，位列全球**TOP10**规模的系统建设及运维经验、**1000+**运维项目经验。



近3年私有云市场MySQL产品&运维服务领导地位，得到行业客户的广泛认可，拥有多家世界500强客户及大型银行客户，在金融行业树立标杆地位。






云树DMP — 多数据库自动化运维管理平台



云树DMP（自动化运维管理平台）

管理区

- 主机管理
- 实例管理
- 监控告警
- 备份恢复
- 读写分离
- 分库分表
- 用户管理
- 灾备管理
- 日志管理
- SQL审核



基础资源



SQLE：多元异构数据库SQL管理方案



OB发行版-ActionDB产品架构

Paxos协议 + 无共享架构 + 分区级高可用


多副本：一般部署为三/五个Zone，每个Zone由多个节点（OBServer）组成

全对等节点：每个节点均有自己的SQL引擎和存储引擎，各自管理不同的数据分区，完全对等


无共享：数据分布在各个节点上，不基于任何共享存储结构（share-nothing）

分区级可用性：可靠性与扩展性的基本单元，自动流量路由、负载均衡、故障转移



数据强一致：多副本 + Paxos分布式选举协议的金融级实现，保证数据（日志）持久化到多数派节点，数据校验规避静默错误




TensorDB® — 爱可生向量数据库企业版软件



公司认证资质



- 国家规划布局内的重点软件企业、国家高新技术企业。
- 国家科技部国家重点研发计划 - “网络协同制造和智能工厂”重点专项。
- 已拥有80多项软件著作权和产品登记证书和**5项已授权核心技术发明专利**（另45+项数据技术专利申报中）。
- 核心产品为多库融合、数据智能应用等产品。
- 数据库标杆客户：工商银行、招商银行、交通银行、农业银行、兴业银行、中国人寿、平安集团、太平洋保险、中国人保、国家电网、上汽集团、上海大众、中国移动、中国电信、华为等40+世界500强，国计民生核心业务的后台数据技术。
- 承担了工信部5所、工业互联网创新中心（上海）、航天科技集团、国家电网等多个重点数据项目。
- 2020年，公司获中国信息协会2020-2021年度信息技术应用创新优秀解决方案奖。
- 2021年上海市重点支持的信创-基础软件企业。



信创生态

74 个软著作权

2010SR067231
爱可生分布式数据库智能管理平台软件V1.0
2010SR067231
爱可生分布式数据库智能管理平台软件V1.0
2017SR616080
云树®分布式数据库软件【简称：CTREE Shard】 V4.0
2017SR639969
云树®数据库集群管理平台软件【简称：CTREE DMP】 V3.0
2017SR660641
云树®数据库云服务平台软件【简称：CTREE RDS】 V4.0
2022SR1299812
云树®数据库SQL质量管理软件【简称：CTREE SQLE】 V1.0
2022SR1551925
云树®数据库软件【简称：ActionDB】 V1.0

24 项技术标准参编

2018	《金融分布式事务数据库白皮书》 信通院云大所
2020	《数据库及应用系统迁移指南》 信通院云大所
2022	《分布式数据库技术金融应用检测指南》 北京国金认证
2022	《信通院 SQL 质量管理平台能力标准》 信通院云大所

开源生态



爱可生开源社区

发消息



爱可生开源社区，提供稳定的 MySQL 企业级开源工具及服务，每年 1024 开源一款优良组件，并持续运营维护。

702 篇原创内容 52 个朋友关注

📺 视频号: simplelogic

爱可生开源社区提供的服务

技术干货

8.0 新特性

故障分析

技术分享

公开课

公开演讲

技术专栏

图解 MySQL

一问一实验

SQL 调优

详解 Prometheus

ClickHouse 系列

社区信息

开源产品

社区活动

社区官网

关于爱可生



技术文章

新增1000+篇
每日一更




《大智小技》

出版第四册
总出版数量破4000+



社区热度

平均阅读量1000+
粉丝量破13000+



触达数据库领域



从业者15000+
社群人数4700+



开源项目

爱可生开源社区是一个专注于数据库领域的技术社区，社区秉持开放、汇聚、协同、众创的精神，为广大数据库从业人员提供稳定的 MySQL 企业级开源工具及服务。

社区在每年的 **10.24** 会开源一款优良组件，并不断汇集社区内更多的创新力量，为数据库开源产品不断赋能。截至目前，爱可生的开源产品在 GitHub 上已获得超过 **2700+** stars (<https://github.com/actiontech>)。



02

向量数据库的概念

非结构化数据正在迅猛增长

int, float,
string, ...

text

json

image
video
audio

domain specific

0 1 2 3 4
5 6 7 8 9



e π

ABCDEFGH

2021.04.10

Abstract
Bigtable is a distributed storage system for managing structured data that is designed to scale to a very large size: petabytes of data across thousands of commodity servers. Many projects at Google store data in Bigtable, including web indexing, Google Earth, and Google Finance. These applications place very different demands on Bigtable, both in terms of data size (from URLs to web pages to satellite imagery) and latency requirements (from backend bulk processing to real-time data serving). Despite these varied demands, Bigtable has successfully provided a flexible, high-performance solution for all of these Google products. In this paper we describe the simple data model provided by Bigtable, which gives clients dynamic control over data layout and format, and we describe the design and implementation of Bigtable.

```
{
  "firstName": "John",
  "lastName": "Smith",
  "isAlive": true,
  "age": 27,
  "address": {
    "streetAddress": "21 2nd Street",
    "city": "New York",
    "state": "NY",
    "postalCode": "10021-3100"
  },
  "phoneNumbers": [
    {
      "type": "home",
      "number": "212 555-1234"
    },
    {
      "type": "office",
      "number": "646 555-4567"
    }
  ],
  "children": [],
  "spouse": null
}
```






Structured data




Unstructured data

机器理解非结构化数据

机器理解数据



AI模型 / 编码手段




大模型正在占领世界



入局大模型的中国企业/科研院所及产品汇总

企业类型	企业/创始人名称	大模型及相关产品
互联网公司	百度	“文心”大模型/文心一言
	阿里	“通义”大模型/通义千问
	腾讯	“混元”大模型/混元助手
	华为	“盘古”大模型
	字节跳动	飞书My AI
	京东	Chat JD
	知乎	“知海图AI”大模型（与面壁科技合作）
	昆仑万维	“天工”大语言模型
	麒麟合盛	“天燕”大模型
	360	360智脑
AI公司	网易	“玉言”预训练大模型
	小米	正在研发，还未公布
	金山办公	WPS AI（大模型由MiniMax提供）
	商汤科技	日日新SenseNova/商量、秒画、如影
	科大讯飞	“讯飞星火”认知大模型
	出门问问	“序列猴子”大模型/奇妙文、言之画
	智谱AI（清华大学技术成果转化）	ChatGLM
	澜舟科技	“孟子MChat”大模型
	毫末智行	“DriveGPT”自动驾驶生成式大模型
	竹间智能	“魔力写作”大模型
初创公司	MiniMax	自研多模态大模型/Glow
	面壁科技	“知海图AI”大模型（与知乎合作）
	聆心智能	超拟人大模型/AI乌托邦
	元语科技	“元语ChatYuan”对话大模型
	云从科技	“行业精灵”大模型研发项目（募集中）
	达观数据	“曹植”大语言模型
	王慧文（美团联合创始人）	光年之外（公司名称）
	李开复（创新工场董事长）	Project AI2.0
	王小川（搜狗公司创始人）	百川智能（公司名称）
	周伯文（前京东AI掌门人）	街远科技（公司名称）
科研院所	复旦大学邱锡朋教授团队	“MOSS”对话式大型语言模型
	中国科学院自动化研究所	“紫东太初”多模态大模型
	上海人工智能实验室	“风乌”天气预报大模型
	北京智源人工智能研究院	“悟道2.0”预训练大模型
教育行业	哈尔滨工业大学	“活字”对话大模型
	网易有道	“子曰”大模型
	学而思	“MathGPT”数学大模型

资料来源：《财经》记者整理



1


Text2SQL

2

Copilot

3

Text2Media



什么是向量数据库


存储通过 **AI 模型提取出来的高维向量**，这些高维向量类似于数学领域中的坐标系的点，标识了不同数据之间的关系，通过向量可以实现数据之间高效的相似性比对，来赋能相应的业务场景。

向量数据库就是可以使用户更加便捷的访问，检索，管理，组织向量数据的一种数据库。


向量化表示





卷积神经网络



向量空间




向量化表示




向量化表示



卷积神经网络




向量空间




近似近邻搜索

卷积神经网络







向量数据库



query

完成搜索所需要的计算支持

- 距离计算
 - 欧式距离
 - 余弦相似度
 - 汉明距离
 -
- TopK排序
- 聚类计算



03


大模型的局限性

大模型的局限性

幻觉问题

私域数据

新增海量数据



YA

金庸的小说有哪些



金庸（原名查良镛）是中国著名的武侠小说作家，他创作了许多广受欢迎的武侠小说。以下是金庸创作的一些著名小说：



1. **《神雕侠侣》**：这是金庸最著名的作品之一，讲述了郭靖和黄蓉的爱情故事，以及他们在江湖中的冒险。小说中的神雕和郭靖黄蓉的故事深受读者喜爱。
2. **《射雕英雄传》**：这部小说描述了郭靖和黄蓉的故事，以及他们在南宋末年的历险。小说中有许多英雄人物，包括郭靖、杨康、杨过等。
3. **《倚天屠龙记》**：这个故事集中讲述了张无忌的冒险，他是一个师承峨眉派的武学高手。小说中涉及了倚天剑、屠龙刀和明教等元素。
4. **《天龙八部》**：这是一部以宋朝为背景的小说，讲述了段誉、乔峰、虚竹等主要角色的冒险和故事。
5. **《笑傲江湖》**：这个故事围绕着南帝北丐东邪西毒等武林高手的生活展开，讲述了华山派林平之的经历。
6. **《白马啸西风》**：小说中的主要角色是段誉，他的父亲段正淳被迫逃亡，而段誉被抚养在草原上。小说讲述了他的成长和冒险。


这些小说是金庸的代表作品，也被称为武侠小说的经典之一，受到了广大读者的热烈欢迎。金庸以其丰富的想象力和生动的描写，创造了许多不朽的武侠经典。

大模型的局限性

幻觉问题

私域数据

新增海量数据





国产数据库是指中国国内开发和生产的各种数据库管理系统（DBMS）。这些数据库系统通常被广泛用于各种应用领域，包括企业、政府、科研和教育。以下是一些中国国产数据库的主要类型和代表性产品：



1. **关系型数据库（RDBMS）**：关系型数据库采用表格结构来存储和管理数据，使用SQL语言进行查询和管理。国内有一些知名的关系型数据库产品，包括：
 - **南大通用数据库（NUDB）**：由南京大学研发，支持分布式数据库和分布式事务处理。
 - **达梦数据库（DMDB）**：达梦数据库系统是一种商业数据库系统，支持大规模数据管理和企业应用。
2. **NoSQL数据库**：NoSQL数据库通常不采用传统的表格结构，而使用各种不同的数据模型，例如文档型、键值型、列族型等。国产NoSQL数据库包括：
 - **华为云Distributed Data Storage (DDS)**：支持分布式存储和多种数据模型。
 - **PingCAP TiDB**：是一个分布式的NewSQL数据库，结合了传统关系型数据库和NoSQL的优势。
3. **大数据数据库**：用于存储和管理大规模数据集，通常具有高度可扩展性和性能。国内的大数据数据库包括：
 - **阿里云AnalyticDB**：阿里云提供的云端大数据仓库和分析服务。
 - **百度OceanBase**：百度开发的分布式关系数据库，用于支持大规模在线应用。
4. **时序数据库**：专用于处理时间序列数据，如传感器数据和日志数据。国产时序数据库包括：
 - **中兴时序数据库**：由中兴通讯开发，用于支持IoT和大数据分析。


需要注意的是，中国的数据库市场不断发展和变化，因此上述数据库产品可能会有更新和新增。此外，国内外企业和开源社区也积极参与数据库领域的创新和发展。根据具体需求和应用场景，可以选择适合的国产数据库产品。

大模型的局限性

幻觉问题

私域数据

新增海量数据



YA

最近一次巴以冲突是什么时候




截止到我知识截止日期为2022年，最近一次巴以冲突发生在2021年5月。这次冲突由多种因素引发，包括耶路撒冷的争议，巴勒斯坦民众和以色列安全部队之间的紧张关系，以及其他政治、宗教和地缘政治因素。冲突导致双方发生冲突，导致了大规模的暴力冲突，造成数百人死亡，包括巴勒斯坦人和以色列人。




请注意，自那时以来可能发生了新的事件和进展，我无法提供最新的信息。建议查阅可靠的新闻来源以获取有关巴以冲突的最新信息。

大模型的局限性如何解决

模型微调



基于检索的大模型





04

解决方案

DBA的常见困扰

业务增长太快，数据库该如何扩展，读写分离、分库分表怎么选？多大的表该做拆分，怎么拆呢？数据咋迁移呢？

Oracle是去掉了，用了一堆开源库，运维太麻烦了。

开源数据库占比越来越大，怎样才能快速掌握它们的最佳实践呢？

前期没有做标准化，现在数据量增长太快，运维效率下降，问题越来越多。


网上流传的双主架构，数据经常不一致，复制老中断，该咋整？

开发drop库了，恢复起来太费劲，有没有快速恢复的方案？

安全扫描又来，数据库又要升级，有没有批量自动化的升级方案？

业务要用的数据库种类太多了，MySQL、Redis、MongoDB、PostgreSQL、TiDB，能不能统一维护起来？


业务抱怨数据库运行缓慢，没有足够信息采集，该如何诊断？



云树DMP — 多数据库自动化运维管理平台



云树DMP (自动化运维管理平台)



系统运维的稳定性从规范化的部署开始



适配计算资源

裸机资源
虚拟机资源



运维效率

分钟级别交付
支持批量安装部署



标准化交付

标准架构
标准配置
标准模板
标准接管



数据库类型

MySQL
Redis
MongoDB
TiDB
Oracle

批量接管数据库实例

本地文件 • 选择文件 未选择任何文件

并发数 • 30

上线检查 • ☐ 已阅读上线检查规范

接管数据库实例操作前,请先阅读上线检查规范

关闭

下载接管模板

保存

整组安装数据库组

数据库组名 • mysql-group1

数据库管理用户 • root

数据库管理用户密码 • *****



生成

端口号 • 3306

sip

请选择一个sip

安装压缩包 • mysql-5.7.25-linux-glibc2.12-x86_64.tar.gz

CPU使用核数 请输入CPU使用核数

内存(MB) 请输入内存

安装架构 • 请选择一个安装架构

一主两从半同步

一主两从组复制


一主一从半同步

高级配置

取消

执行

完整闭环的备份恢复系统



编排

自动编排所有备份任务
发送每天编排报表
异常编排任务告警

备份

全量/增量
物理备份/Binglog 备份
备份自动回收

转储

ftp、磁盘、带库
自动转储，故障无忧
NBU/S3 备份对接

恢复演练

自动恢复演练
指定时间点恢复
故障恢复预测

灾备报告

展示RTO、RPO
备份数据有效性验证

定时健康巡检，快速诊断数据库



健康诊断报告 (自动化定时 + 手工实时)

数据库名称	主机名	端口	版本	状态	连接数	内存使用	磁盘使用
mysql-001	10.10.10.1	3306	5.7.27	运行中	100	100M	100G
mysql-002	10.10.10.2	3306	5.7.27	运行中	100	100M	100G
mysql-003	10.10.10.3	3306	5.7.27	运行中	100	100M	100G
mysql-004	10.10.10.4	3306	5.7.27	运行中	100	100M	100G
mysql-005	10.10.10.5	3306	5.7.27	运行中	100	100M	100G
mysql-006	10.10.10.6	3306	5.7.27	运行中	100	100M	100G
mysql-007	10.10.10.7	3306	5.7.27	运行中	100	100M	100G
mysql-008	10.10.10.8	3306	5.7.27	运行中	100	100M	100G
mysql-009	10.10.10.9	3306	5.7.27	运行中	100	100M	100G
mysql-010	10.10.10.10	3306	5.7.27	运行中	100	100M	100G

库表检查

数据库	表名	引擎	字符集	排序规则	主键	索引	状态
mysql	performance_schema	InnoDB	utf8	utf8_bin	PRIMARY	PRIMARY, INDEX	正常
mysql	performance_schema	InnoDB	utf8	utf8_bin	PRIMARY	PRIMARY, INDEX	正常
mysql	performance_schema	InnoDB	utf8	utf8_bin	PRIMARY	PRIMARY, INDEX	正常
mysql	performance_schema	InnoDB	utf8	utf8_bin	PRIMARY	PRIMARY, INDEX	正常
mysql	performance_schema	InnoDB	utf8	utf8_bin	PRIMARY	PRIMARY, INDEX	正常

错误日志 & DDL 进度分析

时间	主机名	端口	错误类型	错误描述	严重程度	是否致命
2020-04-30 15:04:51	10.10.10.1	3306	Warning	Warning: [Error] 1292, Data truncated for column 'id' at row 1	Warning	否
2020-04-30 15:04:52	10.10.10.1	3306	Warning	Warning: [Error] 1292, Data truncated for column 'id' at row 1	Warning	否
2020-04-30 15:04:53	10.10.10.1	3306	Warning	Warning: [Error] 1292, Data truncated for column 'id' at row 1	Warning	否
2020-04-30 15:04:54	10.10.10.1	3306	Warning	Warning: [Error] 1292, Data truncated for column 'id' at row 1	Warning	否
2020-04-30 15:04:55	10.10.10.1	3306	Warning	Warning: [Error] 1292, Data truncated for column 'id' at row 1	Warning	否

图形化锁分析



慢日志分析

时间	主机名	端口	SQL	耗时	是否慢
2020-04-30 15:04:51	10.10.10.1	3306	SELECT mysql.user	1.200000	是
2020-04-30 15:04:52	10.10.10.1	3306	SELECT mysql.user	1.200000	是
2020-04-30 15:04:53	10.10.10.1	3306	SELECT mysql.user	1.200000	是
2020-04-30 15:04:54	10.10.10.1	3306	SELECT mysql.user	1.200000	是
2020-04-30 15:04:55	10.10.10.1	3306	SELECT mysql.user	1.200000	是

连接分析

分析当前连接执行的SQL情况, 找出运行时间较长的连接, kill 高负载的连接

磁盘空间分析

图形化锁分析

慢日志分析

库表检查

检查出不合理的库表设计, 无主键表影响同步性能; 冗余索引影响插入性能; 主键uuid 影响插入性能

健康报告

多维度掌握数据库的健康情况

成千实例规模，成万监控指标，实时指标展示，告警异常及时



监控数据采集

数据库探活

可用性、资源、性能、容量指标采集

高可用架构探测

自动发现监控对象，无需额外配置操作



可扩展

采用云原生监控构，支持监控数据

sharding，可监控上万个监控指标；


采用错峰采集机制，减小被监控对象的负载压力




告警处理

升级变更期间可设置告警静默，避免无效告警

告警通道可灵活配置，支持邮件、企业微信、短信平台等告警通道




SQL质量管理存在问题



SQL治理需要考虑SQL全生命周期

软件生命周期




问题越早解决成本越低!

第三方统计数据显示: 49.4%的数据库故障是由于SQL不规范、效率低等问题引起

标准发布:上线工单变更发布标准化，杜绝问题SQL流向生产

变更SQL上线发布流程



审核结果 审核通过率100% 审核结果评分100

下载审核报告 下载SQL语句 是否去重

审核状态: 请选择要搜索的审核状态 执行状态: 请选择要搜索的执行状态 审核结果: 请选择要搜索的审核结果 重置 搜索

序号	审核状态	审核结果	执行语句	执行状态	执行结果	回滚语句 (仅提示, 不支持执行回滚)	说明
1	审核完毕		select name from test where id =1;	准备执行			

1 10 条/页

工单进度

- 操作时间:2022-03-21 16:55:14 操作人:admin admin创建了当前工单
- 操作时间:2022-03-21 17:45:14 操作人:demo_user demo_user通过了当前工单的审核
- 操作时间:2022-03-21 17:45:24 操作人:admin admin通过了当前工单的审核
- 操作时间:-- 操作人:--

定时上线 立即上线 驳回

只能在运维时间之内执行立即上线当前数据源的运维时间为: 00:00-06:00

发布效率提升，发布留痕

变更SQL一键执行上线，提升发布效率

手动上线/定时上线

发布留痕，可追溯

建立标准化发布流程

所有发布必须通过平台执行，

线下人情上线减少100%，问题

SQL引起的性能问题减少60%


多种模式发布，批量上线，满足不同场景上线诉求



批量上线需求，涉及多个数据库

分环境域上线场景：生产环境/预发布环境上线

分区域上线场景：国内/国外环境



工单基本信息

* 工单名称: dingdan_0909

工单描述: 订单系统0909发展

* 工单模式: ☒ 相同Sql ☐ 不同Sql

* 数据源: test 数据库: 请选择

* 数据源: test2 数据库: 请选择

* 数据源: ob_test 数据库: 请选择

+ 添加数据源

测试数据库连通性

选择审核SQL语句上传方式: ☒ 输入SQL语句 ☐ 上传SQL文件 ☐ 上传Mybatis的XML文件

* SQL语句: 1 /* input your sql */

工单进度


操作时间:2022-09-16 10:49:34 操作人:admin admin创建了当前工单

操作时间:2022-09-16 12:30:24 操作人:admin admin通过了当前工单的审核

操作时间:-- 操作人:-- [批量立即上线](#)

数据源	状态	上线开始时间	上线结束时间	定时上线时间	待操作人	审核通过率	审核结果评分	操作
mysql-1	定时上线			2022-09-16T21:00:00+08:00	admin	100%	100	立即 定时 取消 上线 上线 时上线
mysql-2	待上线				admin	100%	100	立即上线 定时上线

事后SQL审核



TOP SQL采集审核

- 1.根据采集周期SQLE定期获取数据库TOP SQL语句
- 2.使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

慢日志采集审核

- 1.SQLE实时获取数据库慢日志SQL语句
- 2.定期审核：使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

审计日志采集审核

- 1.SQLE通过客户端程序实时获取数据库慢日志SQL语句
- 2.定期审核：使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。


库表元数据审核

- 1.根据采集周期SQLE定期获取数据库库表元数据信息
- 2.使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

云数据库审核

- 1.SQLE调用RDS的慢日志、审计日志等API获取运行SQL信息
- 2.SQLE使用语法解析器解析SQL语句，获取SQL执行计划
- 3.基于规则和执行计划判断SQL是否存在风险。

SQLE：多元异构数据库SQL管理方案




目前存在什么问题?

故障定位后需要大量人工操作

多表关联SQL开发复杂

SQL审核规则多样




刚上手一款新的数据库不知道该如何排查问题

如何对SQL进行优化观点不一

现场交付人工成本高

```
>tail -f mysql_slow.log.1 | grep Query_time
# Query_time: 0.000715 Lock_time: 0.000056 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000583 Lock_time: 0.000071 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000353 Lock_time: 0.000054 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000725 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000302 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000327 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.001899 Lock_time: 0.000045 Rows_sent: 1 Rows_examined: 1731 Rows_affected: 0
# Query_time: 0.000693 Lock_time: 0.000054 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000318 Lock_time: 0.000055 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000367 Lock_time: 0.000053 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000682 Lock_time: 0.000053 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000301 Lock_time: 0.000056 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000321 Lock_time: 0.000058 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000683 Lock_time: 0.000050 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.002353 Lock_time: 0.000049 Rows_sent: 1 Rows_examined: 1727 Rows_affected: 0
# Query_time: 0.000307 Lock_time: 0.000053 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000327 Lock_time: 0.000057 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000705 Lock_time: 0.000052 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000312 Lock_time: 0.000049 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000315 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.001937 Lock_time: 0.000044 Rows_sent: 1 Rows_examined: 1723 Rows_affected: 0
# Query_time: 0.000701 Lock_time: 0.000059 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
# Query_time: 0.000296 Lock_time: 0.000052 Rows_sent: 1 Rows_examined: 423 Rows_affected: 0
# Query_time: 0.000325 Lock_time: 0.000052 Rows_sent: 7 Rows_examined: 330 Rows_affected: 0
# Query_time: 0.000681 Lock_time: 0.000051 Rows_sent: 1 Rows_examined: 1456 Rows_affected: 0
```

目前存在什么问题？



基于大模型+向量数据库的智能运维解决方案（类知识库）



项目背景：

随着企业数字化进程加速，IT运维工作日益复杂。当前，企业面临的主要运维困难和问题包括以下几点：

- **运维工作量大**：随着系统规模和复杂性的增加，企业的IT设施需要处理的问题数量不断增加，运维工作量巨大。
- **响应速度慢**：传统的人工运维方式，处理问题的速度无法满足快速响应的需求，导致问题解决效率低下。
- **技能门槛高**：复杂的IT系统需要运维人员具有高技能水平，这对企业人才的选拔和培养提出了更高要求。
- **故障预测困难**：传统运维方式往往在故障发生后进行处理，难以实现故障的预测和预防。

方案价值：

- **提高运维效率**：通过智能化的方法，可以自动化处理常见的运维问题，大幅提高运维效率。
- **降低运维成本**：通过自动化运维，减少对人工的依赖，从而降低企业的人力成本。
- **强化故障预防**：通过大模型的预测能力，可以预测潜在的故障和问题，从而实现从被动应对向主动预防的转变。




基于大模型+向量数据库的SQL开发管控解决方案

项目背景:

随着企业数据量的快速增长，SQL开发的复杂性也在不断提高，同时如何有效地对SQL进行审核以保证数据质量和安全性，成为了一个重要的问题。当前在整个SQL的生命周期中存在如下问题：

- **效率低**：人工进行SQL开发与审核不仅效率低，且容易出错，无法满足大规模、复杂的数据处理需求
- **审核质量不稳定**：人工审核依赖于个人经验和技能，审核质量难以保证，存在较大的风险
- **技能门槛高**：SQL审核需要深入理解数据库和SQL语句，对人才的要求较高





05

优化思路


GPU能做什么

CPU



- * Low compute density
- * Complex control logic
- * Large caches (L1\$/L2\$, etc.)
- * Optimized for serial operations
 - Fewer execution units (ALUs)
 - Higher clock speeds
- * Shallow pipelines (<30 stages)
- * Low Latency Tolerance
- * Newer CPUs have more parallelism

GPU



- * High compute density
- * High Computations per Memory Access
- * Built for parallel operations
 - Many parallel execution units (ALUs)
 - Graphics is the best known case of parallelism
- * Deep pipelines (hundreds of stages)
- * High Throughput
- * High Latency Tolerance
- * Newer GPUs:
 - Better flow control logic (becoming more CPU-like)
 - Scatter/Gather Memory Access
 - Don't have one-way pipelines anymore

GPU长啥样





Figure 6. GA100 Full GPU with 128 SMs (A100 Tensor Core GPU has 108 SMs)

GPU长啥样




Figure 7. GA100 Streaming Multiprocessor (SM)

GPU加速排序举例



GPU加速排序举例：局部放大图




shfl_xor (1) //L=1

shfl_xor (3) //L=2
shfl_xor (1)

shfl_xor (7) //L=4
shfl_xor (2)
shfl_xor (1)


TensorDB® — 爱可生向量数据库企业版软件





异构计算支持



- GPU向量计算加速
- TensorDB与国产化GPU（如华为昇腾，天数智芯，海光等）进行深度适配
- 单机多卡，多机多卡



国产化兼容适配



异构计算：Ascend




使用MindSpore框架搭建的Kmeans训练模型

性能指标	Pytorch-CPU	Pytorch-GPU	MindSpore-CPU	MindSpore-GPU
训练速度 (s/iter)	0.08~0.8	0.13	0.14	0.06
查询召回率	98%	98%	99.3%	99.3%

全应用流程中使用到的部分自定义昇腾算子测试结果

性能指标	昇腾Tik-Matmul算子	numpy实现 Matmul	昇腾DSL-Hamming算子	numpy实现 Hamming
平均单次执行速度(ms)	0.18	0.7	0.015	0.05

异构计算：ASCEND



昇腾硬件设备架构

通过利用昇腾设备，索引构建时间**减少了十倍以上**

	Train time(s)	Build time(s)	Search time(s)
Faiss PQ in Python	1.922534	0.153201	0.018154
Faiss IVFPQ in Python	2.102822	0.179002	0.009068
Ascend IVFPQ (昇腾L2Loss算子)	—	0.956889	0.0227027
Ascend IVFPQR (自定义nL2算子)	—	0.015276	0.00575

Input: "Juliet was in love with someone whose name starts with R. His name was"

" Romeo. Juliet, thou hast good luck; and I'll love it better than my life,"


" Romeo, and at Mantua was slain, I think his heart is broke."

Input: "Juliet was in love with someone whose name starts with B. His name was"


" Barnardine. What, and no love? I'll ne'er"

" Barnardine; he is my husband's friend, and he is in love with her"


简单的文本替换很难改变模型内部记忆的知识



微调方法: Freeze




微调方法：P-tuning



- P-Tuning(<https://arxiv.org/abs/2103.10385>), 仅对大模型的Embedding加入新的参数。
- P-Tuning-V2(<https://arxiv.org/abs/2110.07602>), 将大模型的Embedding和每一层前都加上新的参数。


微调方法: Lora

LORA



LoRA 的思想很简单:

- 在原始 PLM (Pre-trained Language Model) 旁边增加一个旁路, 做一个降维再升维的操作, 来模拟所谓的 `intrinsic rank`。
- 训练的时候固定 PLM 的参数, 只训练降维矩阵 A 与升维矩阵 B 。而模型的输入输出维度不变, 输出时将 BA 与 PLM 的参数叠加。
- 用随机高斯分布初始化 A , 用 0 矩阵初始化 B , 保证训练的开始此旁路矩阵依然是 0 矩阵。




大语言模型在知识库项目中落地的突出问题


第一，权衡文档长度和返回文档数据的问题。这个本质上是召回数据相关性的问题。而召回数据相关性的影响方面很多，既包括文档的切分，也包括文档query输入的清晰度，因此现在也出现了从多query、多召回策略以及排序修正等多个方案。

第二，关于问答答案散落在多个文档以及多个文档内部段落里的问题，这个问题的根在于，在有限的上下文窗口内，不同的答案很分散，不容易都放在窗口之内，因此需要将文本进行聚类（主题分割），尽可能地让有限的窗口下能塞满多个主题的内容。

第三，引文生成的问题。现有的方案都是先召回一堆文档，然后让大模型根据文档进行作答，但其中更重要的是能够自动的生成引文角标。




基于动态规划的方案



基于摘要的方案


多query查询



RRF simply sorts the documents according to a naive scoring formula. Given a set D of documents to be ranked and a set of rankings R , each a permutation on $1..|D|$, we compute

$$RRFscore(d \in D) = \sum_{r \in R} \frac{1}{k + r(d)},$$

where $k = 60$ was fixed during a pilot investigation and not altered during subsequent validation. Our intuition in



技术即服务

Technology as a Service

谢谢观看！

