

向量数据库在国产化替代潮中的机遇和实践

上海爱可生信息技术股份有限公司 阎虎青

目录

- 1 向量数据库的概念
- 2 向量数据库的检索
- 3 GPU加速简介
- 4 国产硬件的适配
- 5 解决方案

01




向量数据库的概念

domain specific




Unstructured data

机器理解非结构化数据

机器理解数据



AI模型 / 编码手段





大模型正在占领世界



入局大模型的中国企业/科研院所及产品汇总

企业类型	企业/创始人名称	大模型及相关产品
互联网公司	百度	“文心”大模型/文心一言
	阿里	“通义”大模型/通义千问
	腾讯	“混元”大模型/混元助手
	华为	“盘古”大模型
	字节跳动	飞书My AI
	京东	Chat JD
	知乎	“知海图AI”大模型（与面壁科技合作）
	昆仑万维	“天工”大语言模型
	麒麟合盛	“天燕”大模型
	360	360智脑
AI公司	网易	“玉言”预训练大模型
	小米	正在研发，还未公布
	金山办公	WPS AI（大模型由MiniMax提供）
	商汤科技	日日新SenseNova/商量、秒画、如影
	科大讯飞	“讯飞星火”认知大模型
	出门问问	“序列猴子”大模型/奇妙文、言之画
	智谱AI（清华大学技术成果转化）	ChatGLM
	澜舟科技	“孟子MChat”大模型
	毫末智行	“DriveGPT”自动驾驶生成式大模型
	竹间智能	“魔力写作”大模型
初创公司	MiniMax	自研多模态大模型/Glow
	面壁科技	“知海图AI”大模型（与知乎合作）
	聆心智能	超拟人大模型/AI乌托邦
	元语科技	“元语ChatYuan”对话大模型
	云从科技	“行业精灵”大模型研发项目（募集中）
	达观数据	“曹植”大语言模型
	王慧文（美团联合创始人）	光年之外（公司名称）
	李开复（创新工场董事长）	Project AI2.0
	王小川（搜狗公司创始人）	百川智能（公司名称）
	周伯文（前京东AI掌门人）	街远科技（公司名称）
科研院所	复旦大学邱锡朋教授团队	“MOSS”对话式大型语言模型
	中国科学院自动化研究所	“紫东太初”多模态大模型
	上海人工智能实验室	“风乌”天气预报大模型
	北京智源人工智能研究院	“悟道2.0”预训练大模型
教育行业	哈尔滨工业大学	“活字”对话大模型
	网易有道	“子曰”大模型
	学而思	“MathGPT”数学大模型

资料来源：《财经》记者整理




大模型的局限性

幻觉问题

私域数据

新增海量数据



YA

金庸的小说有哪些



金庸（原名查良镛）是中国著名的武侠小说作家，他创作了许多广受欢迎的武侠小说。以下是金庸创作的一些著名小说：



1. **《神雕侠侣》**：这是金庸最著名的作品之一，讲述了郭靖和黄蓉的爱情故事，以及他们在江湖中的冒险。小说中的神雕和郭靖黄蓉的故事深受读者喜爱。
2. **《射雕英雄传》**：这部小说描述了郭靖和黄蓉的故事，以及他们在南宋末年的历险。小说中有许多英雄人物，包括郭靖、杨康、杨过等。
3. **《倚天屠龙记》**：这个故事集中讲述了张无忌的冒险，他是一个师承峨嵋派的武学高手。小说中涉及了倚天剑、屠龙刀和明教等元素。
4. **《天龙八部》**：这是一部以宋朝为背景的小说，讲述了段誉、乔峰、虚竹等主要角色的冒险和故事。
5. **《笑傲江湖》**：这个故事围绕着南帝北丐东邪西毒等武林高手的生活展开，讲述了华山派林平之的经历。
6. **《白马啸西风》**：小说中的主要角色是段誉，他的父亲段正淳被迫逃亡，而段誉被抚养在草原上。小说讲述了他的成长和冒险。


这些小说是金庸的代表作品，也被称为武侠小说的经典之一，受到了广大读者的热烈欢迎。金庸以其丰富的想象力和生动的描写，创造了许多不朽的武侠经典。

大模型的局限性

幻觉问题

私域数据

新增海量数据





国产数据库是指中国国内开发和生产的各种数据库管理系统（DBMS）。这些数据库系统通常被广泛用于各种应用领域，包括企业、政府、科研和教育。以下是一些中国国产数据库的主要类型和代表性产品：



1. **关系型数据库（RDBMS）**：关系型数据库采用表格结构来存储和管理数据，使用SQL语言进行查询和管理。国内有一些知名的关系型数据库产品，包括：
 - **南大通用数据库（NUDB）**：由南京大学研发，支持分布式数据库和分布式事务处理。
 - **达梦数据库（DMDB）**：达梦数据库系统是一种商业数据库系统，支持大规模数据管理和企业应用。
2. **NoSQL数据库**：NoSQL数据库通常不采用传统的表格结构，而使用各种不同的数据模型，例如文档型、键值型、列族型等。国产NoSQL数据库包括：
 - **华为云Distributed Data Storage (DDS)**：支持分布式存储和多种数据模型。
 - **PingCAP TiDB**：是一个分布式的NewSQL数据库，结合了传统关系型数据库和NoSQL的优势。
3. **大数据数据库**：用于存储和管理大规模数据集，通常具有高度可扩展性和性能。国内的大数据数据库包括：
 - **阿里云AnalyticDB**：阿里云提供的云端大数据仓库和分析服务。
 - **百度OceanBase**：百度开发的分布式关系数据库，用于支持大规模在线应用。
4. **时序数据库**：专用于处理时间序列数据，如传感器数据和日志数据。国产时序数据库包括：
 - **中兴时序数据库**：由中兴通讯开发，用于支持IoT和大数据分析。


需要注意的是，中国的数据库市场不断发展和变化，因此上述数据库产品可能会有更新和新增。此外，国内外企业和开源社区也积极参与数据库领域的创新和发展。根据具体需求和应用场景，可以选择适合的国产数据库产品。

大模型的局限性

幻觉问题

私域数据

新增海量数据



YA

最近一次巴以冲突是什么时候




截止到我知识截止日期为2022年，最近一次巴以冲突发生在2021年5月。这次冲突由多种因素引发，包括耶路撒冷的争议，巴勒斯坦民众和以色列安全部队之间的紧张关系，以及其他政治、宗教和地缘政治因素。冲突导致双方发生冲突，导致了大规模的暴力冲突，造成数百人死亡，包括巴勒斯坦人和以色列人。




请注意，自那时以来可能发生了新的事件和进展，我无法提供最新的信息。建议查阅可靠的新闻来源以获取有关巴以冲突的最新信息。


大模型的局限性如何解决

模型微调



基于检索的大模型





什么是向量数据库

存储通过 **AI 模型提取出来的高维向量**，这些高维向量类似于数学领域中的坐标系的点，标识了不同数据之间的关系，通过向量可以实现数据之间高效的相似性比对，来赋能相应的业务场景。

向量数据库就是可以使用户更加便捷的访问，检索，管理，组织向量数据的一种数据库。


02

向量数据库的检索


向量化表示





卷积神经网络





向量空间





向量化表示



向量化表示



向量化表示




近似近邻搜索




query

卷积神经网络







向量数据库



完成搜索所需要的计算支持

- 距离计算
 - 欧式距离
 - 余弦相似度
 - 汉明距离
 -
- TopK排序
- 聚类计算



03

GPU加速简介


GPU能做什么

CPU



- * Low compute density
- * Complex control logic
- * Large caches (L1\$/L2\$, etc.)
- * Optimized for serial operations
 - Fewer execution units (ALUs)
 - Higher clock speeds
- * Shallow pipelines (<30 stages)
- * Low Latency Tolerance
- * Newer CPUs have more parallelism

GPU



- * High compute density
- * High Computations per Memory Access
- * Built for parallel operations
 - Many parallel execution units (ALUs)
 - Graphics is the best known case of parallelism
- * Deep pipelines (hundreds of stages)
- * High Throughput
- * High Latency Tolerance
- * Newer GPUs:
 - Better flow control logic (becoming more CPU-like)
 - Scatter/Gather Memory Access
 - Don't have one-way pipelines anymore

GPU长啥样





Figure 6. GA100 Full GPU with 128 SMs (A100 Tensor Core GPU has 108 SMs)

GPU长啥样



Figure 7. GA100 Streaming Multiprocessor (SM)

GPU加速排序举例



shfl_xor (1) //L=1


shfl_xor (3) //L=2
shfl_xor (1)

shfl_xor (7) //L=4
shfl_xor (2)
shfl_xor (1)

shfl_xor (15) //L=8
shfl_xor (4)
shfl_xor (2)
shfl_xor (1)

shfl_xor (31) //L=16
shfl_xor (8)
shfl_xor (4)
shfl_xor (2)
shfl_xor (1)

GPU加速排序举例：局部放大图



shfl_xor (1) //L=1



shfl_xor (3) //L=2
shfl_xor (1)

shfl_xor (7) //L=4
shfl_xor (2)
shfl_xor (1)

04

国产硬件的适配


TensorDB[®] — 爱可生向量数据库企业版软件





异构计算支持



- GPU向量计算加速
- TensorDB与国产化GPU（如华为昇腾，天数智芯，海光等）进行深度适配
- 单机多卡，多机多卡



国产化兼容适配



异构计算：ASCEND




使用MindSpore框架搭建的Kmeans训练模型

性能指标	Pytorch-CPU	Pytorch-GPU	MindSpore-CPU	MindSpore-GPU
训练速度 (s/iter)	0.08~0.8	0.13	0.14	0.06
查询召回率	98%	98%	99.3%	99.3%

全应用流程中使用到的部分自定义昇腾算子测试结果

性能指标	昇腾Tik-Matmul算子	numpy实现Matmul	昇腾DSL-Hamming算子	numpy实现Hamming
平均单次执行速度(ms)	0.18	0.7	0.015	0.05

异构计算：ASCEND



通过利用昇腾设备，索引构建时间**减少了十倍以上**

	Train time(s)	Build time(s)	Search time(s)
Faiss PQ in Python	1.922534	0.153201	0.018154
Faiss IVFPQ in Python	2.102822	0.179002	0.009068
Ascend IVFPQ (昇腾L2Loss算子)	-	0.956889	0.0227027
Ascend IVFPQR (自定义nL2算子)	-	0.015276	0.00575

05

解决方案

应用场景及商业价值

互联网服务

多模态信息检索，
例如以图搜图

金融领域

高维向量提取，
加速金融支付，
提高风控能力

医疗行业

蛋白质性质预测，
智能病理分析，
智能问诊，

大模型基础设施

实现本地数据在不出域的情况下
搭建大模型的私域应用。

工业制造

赋能工业图像检测，
质量监控与良率分析

安防行业

智能安防


项目背景：

随着企业数字化进程加速，IT运维工作日益复杂。当前，企业面临的主要运维困难和问题包括以下几点：

- 运维工作量大
- 响应速度慢
- 技能门槛高
- 知识难以传承/检索



基于大模型+向量数据库的智能运维解决方案（类知识库）



基于大模型+向量数据库的智能运维解决方案（类知识库）



MySQL报错: Too many open files, 经常重启有什么可能的原因?

可能的原因是大量的 `order by` 语句产生了临时文件, 导致打开文件数量过多。此外, 还需要检查 `ulimit open files` 设置、MySQL的`innodb_open_files`配置、`idb`文件数量、链接数量监控、临时表和临时表空间配置等方面。同时, 可以通过观察 `slow log` 记录的慢查询和临时文件过多的情况来进一步诊断问题。解决方案包括统一数据类型、设置 `internal_tmp_mem_storage_engine=MEMORY`、设置 `innodb_open_files=102400`、开启 `coredump`、定时任务监控等。


GPT4: 为了解决这个问题, 你可以考虑以下步骤:

1. 增加操作系统的文件描述符限制。
2. 增加MySQL的`open_files_limit`。
3. 检查并调整`table_open_cache`的值。
4. 考虑更改数据存储引擎 (例如从MyISAM迁移到InnoDB)。
5. 优化数据库设计, 减少不必要的表。
6. 定期检查并清理旧的日志文件。


基于大模型+向量数据库的SQL开发管控解决方案

项目背景：

随着企业数据量的快速增长，SQL开发的复杂性也在不断提高，同时如何有效地对SQL进行审核以保证数据质量和安全性，成为了一个重要的问题。当前在整个SQL的生命周期中存在如下问题：**效率低**，**审核质量不稳定**，**技能门槛高**



基于大模型+向量数据库的SQL开发管控解决方案



基于大模型+向量数据库的SQL开发管控解决方案

SQL audit

Chatbot

你的任务是:请确定输入的 SQL 语句是否符合规则列表中的所有规则

输入是: SELECT * FROM table1 WHERE column1 IN (SELECT column2 FROM table2 LIMIT 1000);


规则列表: '避免使用不必要的内置函数', '表中包含的列数超过40列'

不符合以下规则:表中包含的列数超过40列

```
-- Using valid SQLite, answer the following questions for the tables provided above.
```

```
-- 请帮我写sql语句查询工程师这一工种的最低工资、最高工资、平均工资?
```

```
SELECT MIN(salary), MAX(salary), AVG(salary) FROM employees WHERE job_id = '工程师';
```



技术即服务

Technology as a Service

谢谢观看！

